

Procesamiento de Lenguaje Natural I

Vectorización de texto

Docentes:

MSc. Fernando Silva

MSc. Josselyn Ordoñez

emails: fernandosilva.clases2@gmail.com

josselynsofia@gmail.com

Programa del curso



Clase 1: Introducción a NLP, Vectorización de documentos.

Clase 2: Word embeddings.

Clase 3: Redes recurrentes: Elman, LSTM y GRU.

Clase 4: Modelos de lenguaje y generación de secuencias.

Clase 5: CNNs para PLN.


Clase 6: Modelos Seq2seq.

Clase 7: Mecanismo de atención, Transformers.

Clase 8: Grandes modelos de lenguaje.


***Unidades con desafíos de código a presentar al finalizar el curso.**

Link Github de la materia




https://github.com/FIUBA-Posgrado-Inteligencia-Artificial/procesamiento_lenguaje_natural


Desafíos propuestos




Vectorización de texto



Word embeddings



Generación de
secuencias




Modelos seq2seq

¿Cómo se entregan las resoluciones?



<https://forms.gle/qUF9abx9uziTN9A49>

Envían por formulario el link
del repositorio, ingresando
sus datos.



¿Cómo se evaluarán los desafíos?



Nota máxima si la primera entrega se hace hasta última hora de Argentina del jueves de la clase...

	1	2	3	4	5	6	7	8
Desafío 1	10	10	10	9	9	8	7	6
Desafío 2		10	10	10	9	9	8	7
Desafío 3				10	10	10	9	8
Desafío 4						10	10	10

Los desafíos son individuales y deben ser subidos a un repositorio personal.

PARA APROBAR EL CURSO TODOS LOS DESAFÍOS DEBEN SER ENTREGADOS Y EVALUADOS SATISFACTORIAMENTE ANTES DE LA FECHA DEL CIERRE DE NOTAS

Agenda



- Introducción al Procesamiento de Lenguaje Natural (NLP)
- Historia del NLP
- Aplicaciones de NLP
- Tareas de NLP
- Preprocesamiento de Texto
- Vectorización de Texto
- Machine Learning para NLP

Introducción al Procesamiento de Lenguaje Natural (NLP)



¿Qué es el lenguaje?
¿Qué se necesita para entenderlo?

¿Qué es el lenguaje?



Desde un punto de vista de la **Lingüística**:

- El Lenguaje es un sistema de símbolos más reglas. Contempla semántica, sintaxis, y es pragmática.
- Chomsky menciona la idea de gramática generativa:
 - Donde tenemos un conjunto de reglas capaces de generar todas las oraciones correctas de un idioma.
 - Con pocas reglas podemos generar infinitas oraciones.
 - **En NLP clásico se intentó modelar lenguaje con reglas tipo Chomsky.**



¿Qué es el lenguaje?



Desde un punto de vista de la **Lingüística**:

- El Lenguaje es un sistema de símbolos más reglas. Contempla semántica, sintaxis, y es pragmática.
- ¿Los Large Language Models (LLMs) conocen gramática o solo patrones?
 - ¿son loros estocásticos? (**Clase 7 y 8**)

On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? 🦜

Emily M. Bender*
ebender@uw.edu
University of Washington
Seattle, WA, USA

Angelina McMillan-Major
aymm@uw.edu
University of Washington
Seattle, WA, USA

Timnit Gebru*
timnit@blackinai.org
Black in AI
Palo Alto, CA, USA

Shmargaret Shmitchell
shmargaret.shmitchell@gmail.com
The Aether

On the Dangers of Stochastic Parrots:
Can Language Models Be Too Big? (2021)

¿Qué es el lenguaje?



Desde un punto de vista de la **Filosofía**:

- Ludwig Wittgenstein propone una idea clave:

“El significado de una palabra es su uso en el lenguaje.”

- Esto rompe con la idea clásica de que las palabras tienen significado fijo.
- Por ejemplo la palabra “banco” puede significar:
 - Banco financiero
 - Banco para sentarse
 - Banco de peces

El significado depende del contexto.



¿Qué es el lenguaje?




Desde un punto de vista de la **Filosofía**:

- Ludwig Wittgenstein propone una idea clave:

“El significado de una palabra es su uso en el lenguaje.”

- Esta idea está muy relacionada a un concepto llamado **embeddings** (**Clase 2**):



¿Qué es el Procesamiento de Lenguaje Natural?



El procesamiento de lenguaje natural (PLN o NLP) es el área de la Inteligencia Artificial que desarrolla modelos computacionales capaces de representar, procesar, comprender y generar lenguaje humano mediante métodos algorítmicos y estadísticos.

Desde IA, NLP implica cuatro cosas clave:

- 1.- **Representación:** Transformar lenguaje (texto o voz) en estructuras matemáticas
- 2.- **Modelado:** Construir funciones que capturen regularidades del lenguaje.
- 3.- **Inferencia:** Dado un input lingüístico, producir una salida coherente.
- 4.- **Aprendizaje:** Ajustar parámetros a partir de datos textuales masivos.

Manifestaciones del Lenguaje



Lenguaje hablado
En NLP: Speech
Processing



Lenguaje escrito
En NLP: Desde N-Grams
hasta Transformers





Lenguaje gestual
En NLP: Desde Sign
Language Recognition
hasta MultiModalidad



Lenguaje digital
En NLP: Desde Sentiment
analysis hasta Topic
modeling

Historia del NLP

Test de turing (1950)



¿Puede una máquina hablar como si fuera un humano?

Eliza (1964) - Primer bot NLP



Welcome to

```
EEEEEE LL      IIII ZZZZZZZZ  AAAAA
EE      LL      II       ZZ  AA  AA
EEEEEE LL      II       ZZZ  AAAAAA
EE      LL      II       ZZ  AA  AA
EEEEEE LLLLLL IIII ZZZZZZZZ AA  AA
```

Eliza is a mock Rogerian psychotherapist.

The original program was described by Joseph Weizenbaum in 1966.

This implementation by Norbert Landsteiner 2005.

ELIZA: Please tell me what's been bothering you.

YOU: I don't really know

ELIZA: Do you wish to be able to really know ?

YOU: Hmm.. well, I guess yes

ELIZA: Do you say you guess yes for some special reason ?

YOU: I don't really know

ELIZA: Does that trouble you ?

YOU: What do you think?

ELIZA: What are your feelings now ?



YOU: Sad

ELIZA: Does talking about this bother you ?

YOU: █

Se basaba en encontrar las palabras claves del texto y utilizarlas para formular una pregunta


Statistical Machine Translation (1990)



IBM introduce los SMT. Los cuales se basan en probabilidad para traducir texto de un idioma a otro.

Estos modelos son conocidos por su enfoque de alineación de palabras y su uso de datos paralelos para aprender traducciones.


Deep Learning (2012 - ...)



Reduce esfuerzos
manuales.


Tres ingredientes
esenciales: Hardware,
Data e Investigación

Transformer y Generative AI (2017 - ...)



En 2017 se presenta el paper “Attention is All You Need” donde se propone la arquitectura Transformer, marcando así el inicio de Generative AI.





Créditos: Dataiku

Aplicaciones de NLP

Machine Translation



how do I say "hello world" in french

 All

 Images

 Shopping

 Videos

 News

 More

Settings

Tools

About 2,660,000 results (0.71 seconds)

English - detected ▼



French ▼

hello world



Bonjour le monde




[Open in Google Translate](#)

[Feedback](#)

Asistentes de Voz



Clasificación de Texto




Chatbot




Tareas de NLP

Clasificación



Tagging




Tagging



Person p Loc l Org o Event e Date d Other z

Barack Hussein Obama II * (born August 4, 1961 *) is an American * attorney and politician who served as the 44th President of the United States * from January 20, 2009 *, to January 20, 2017 *. A member of the Democratic Party *, he was the first African American * to serve as president. He was previously a United States Senator * from Illinois * and a member of the Illinois State Senate *.

Autocompletado





ChatGPT ▾

 Oferta gratis


 Memoria completa


¿Por dónde empezamos?

+ Pregunta lo que quieras




Summarization






Tareas de NLP



Preprocesamiento de texto

Preprocesamiento de texto

[LINK GLOSARIO](#)



Normalización básica




- Lowercasing
- Eliminar signos de puntuación
- Quitar caracteres raros



Tokenization



Proceso en el cual una oración o documento es segmentado en términos individuales. Una vez finalizada la segmentación cada término único es referenciado mediante un token.




Tokenization



A primera vista parece que tokenizar es “solo hacer split”, pero tenemos los siguientes escenarios:

- abreviaturas como **D.C.**
- nombres compuestos como **New York**
- contracciones como “**doesn't**” ó “**could't've**”
- nombres como “**SARS-Cov-2**” o “**R2-D2**”
- con idiomas como el **chino**, que no tienen espacios en blanco
- o idiomas como el **turco**, donde una sola palabra puede expresar tanta información como una oración completa

Tokenization




Stemming



Aplica reglas de eliminación de patrones recurrentes de la lengua. El resultado es una palabra truncada que no será necesariamente la raíz morfológica de la palabra.

Regla: Eliminar los sufijos



plural irregular

especimen, especímenes

régimen, regímenes

Stemming



[the, dogs, are,
running]



Stemming





[the, dog, are,
runn]

Lematización (lemmatization)



Devuelve la raíz morfológica de una palabra. Para ello se necesita un diccionario del idioma con todas las declinaciones posibles de las palabras raíz.



Lematización (lemmatization)



[the, dogs, are,
running]




Lemmatization




[the, dog, be, run]

Stemming vs Lemmatization



Stemming



Lemmatization

Stemming vs Lemmatization



Stemming

Ventajas: Rápido y simple.

Desventajas: Puede producir raíces no válidas y perder precisión semántica.

Lemmatization


Ventajas: Produce palabras válidas y mantiene la precisión semántica.

Desventajas: Puede ser más lenta y requiere recursos adicionales (como WordNet).

Stop words



Palabras que no aportan valor al significado de una oración ya que son muy frecuentes o comunes en el lenguaje



*Argentina, oficialmente, República Argentina, es un país soberano **de** América **del** Sur, ubicado **en** el extremo sur y sudeste **de** dicho subcontinente. Adopta **la** forma **de** gobierno republicana, democrática, representativa y federal.*

Argentina, oficialmente, República Argentina, es país soberano América Sur, ubicado extremo sur sudeste dicho subcontinente. Adopta forma gobierno republicana, democrática, representativa federal.

Practiquemos lo visto hasta ahora



Colab




Vectorización de Texto

Vectorización de texto



[LINK GLOSARIO](#)



Término t : palabra/símbolo "t" del documento

Document: su largo es variable, normalmente una sentencia/oración/párrafo.

Corpus: conjunto de documentos, forman todo el vocabulario.

No podemos ingresar texto
a una red
¿Cómo transformamos
palabras a números?

vectorización




Vectores de
palabras/documentos

Vectores de frecuencia/conteo



"Por cada documento en el corpus se calcula un vector que representa cuántas veces cada palabra del vocabulario aparece en ese documento"



Los vectores tienen el tamaño del vocabulario

Bolsa de palabras (BOW)



Raw Text

Bag-of-words
vector


it is a puppy and it
is extremely cute



it	2
they	0
puppy	1
and	1
cat	0
aardvark	0
cute	1
extremely	1
...	...

Bag of Words representa un documento mediante un vector basado en la presencia o frecuencia de palabras del vocabulario, ignorando el orden en el que aparecen.

Bolsa de palabras (BOW)



Bag of Words representa un documento mediante un vector basado en la presencia o frecuencia de palabras del vocabulario, **ignorando el orden en el que aparecen.**

Bolsa de palabras (BOW)



Document D1	<i>The child makes the dog happy</i> the: 2, dog: 1, makes: 1, child: 1, happy: 1
Document D2	<i>The dog makes the child happy</i> the: 2, child: 1, makes: 1, dog: 1, happy: 1




	child	dog	happy	makes	the	BoW Vector representations
D1	1	1	1	1	2	[1,1,1,1,2]
D2	1	1	1	1	2	[1,1,1,1,2]

Bag of Words representa un documento mediante un vector basado en la presencia o frecuencia de palabras del vocabulario, **ignorando el orden en el que aparecen.**

Vectores Binary Bag of Words




"Por cada documento en el corpus se calcula un vector que representa si cada palabra del vocabulario aparece o no en ese documento"




que	bueno	esta	muy	excelente
1	1	1	0	0
0	1	1	1	0
0	0	1	0	1

Analizar un texto relacionado con calentamiento global (global climate)

Texto con Stop Words




Texto sin Stop Words



Las Stop Words pueden depender del contexto del corpus.

Stop words

Zipf's Law



TF-IDF (Term frequency-Inverse document frequency)



Se utiliza como indicador de cuán importante es una palabra (término) en un documento.

$$\text{TF-IDF}_{(n,d)} = \text{TF}_{(n,d)} \times \text{IDF}_{(n)}$$

Peso de un término (n) en un documento (d)

Frecuencia de aparición de un término (n) en un documento (d)

Factor IDF de un término (n)

Vector IDF (Inverse Document Frequency)



"Proporción de documentos en el corpus que poseen el término"

También suele utilizarse el logaritmo en base 2, su función es conseguir un coeficiente bajo, fácil de manejar


N es el número total de documentos de la colección.

$$\text{IDF}_{(n)} = \log_{10} \frac{N}{\text{DF}_{(n)}}$$

DF (Document Frequency) es el número documentos en los que aparece el término (n) a lo largo de toda la colección

Si el término aparece en todos los documentos el IDF será cero (es popular y por lo tanto aporta poco valor)

Vector IDF



que	bueno	esta	muy	excelente
$\log(3/1)$	$\log(3/2)$	$\log(3/3)$	$\log(3/1)$	$\log(3/1)$
0.477	0.176	0	0.477	0.477

que	bueno	esta	muy	excelente
0.477	0.176	0	0.477	0.477

Se obtiene como la división de la cantidad de documentos sobre la suma en axis=0 (vertical) del CountVectorizer.

Vector TF-IDF



“Que bueno que esta”

“Esta muy bueno”

“Esta excelente”

Vocabulario:
{“que”, “bueno”, “esta”, “muy”,
“excelente”}

IDF

que	bueno	esta	muy	excelente
$\log(3/1)$	$\log(3/2)$	$\log(3/3)$	$\log(3/1)$	$\log(3/1)$

TF-IDF

que	bueno	esta	muy	excelente
$2 * \log(3/1)$	$1 * \log(3/2)$	$1 * \log(3/3)$	$0 * \log(3/1)$	$0 * \log(3/1)$
$0 * \log(3/1)$	$1 * \log(3/2)$	$1 * \log(3/3)$	$1 * \log(3/1)$	$0 * \log(3/1)$
$0 * \log(3/1)$	$0 * \log(3/2)$	$1 * \log(3/3)$	$0 * \log(3/1)$	$1 * \log(3/1)$

Esparsidad de los vectores de conteos



One-Hot Encoding

The quick brown fox jumped over the brown dog



	cat	the	quick	brown	fox	jumped	over	dog	bird	flew	...	kangaroo	house
time	0	1	0	0	0	0	0	0	0	0	...	0	0
	0	0	1	0	0	0	0	0	0	0	...	0	0
	0	0	0	1	0	0	0	0	0	0	...	0	0
	0	0	0	0	1	0	0	0	0	0	...	0	0
	0	0	0	0	0	1	0	0	0	0	...	0	0
	0	0	0	0	0	0	1	0	0	0	...	0	0
	0	1	0	0	0	0	0	0	0	0	...	0	0
	0	0	0	1	0	0	0	0	0	0	...	0	0
	0	0	0	0	0	0	0	1	0	0	...	0	0

Dictionary Size

¡El idioma inglés tiene más de 180.000 palabras en su vocabulario en uso!

¡La representación es sumamente rara!
(poco densa)

No estamos aprovechando eficientemente la dimensionalidad del espacio de vectores.

Similitud entre documentos



¿Cómo medimos qué tan parecidos son dos textos o palabras comparando el significado de sus vectores?


En NLP clásico (TF-IDF, BoW):

- Palabras frecuentes pueden tener vectores con mayor norma.

Si usamos Euclidiana:

- Documentos largos parecen más lejos
- Palabras frecuentes dominan


Coseno normaliza eso.



Distancia Euclidean

$$d(x, y) = \sqrt{\sum_{i=1}^n (y_i - x_i)^2}$$

Mide distancia absoluta en el espacio.
Depende fuertemente de la magnitud.



Similitud Coseno

$$\cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|}$$


Mide el ángulo entre vectores.
Ignora la magnitud y compara orientación.

Relación entre textos: Similitud coseno

Forma de medir qué tan "cerca" está una frase de otra, pero no por su longitud, sino por su **dirección**.

Doc1  "Cada equipo en el campo tiene hasta once jugadores..."

Doc2  "... el equipo Argentino presentó a todos sus jugadores titulares..."



Similitud coseno = 1 → los vectores tienen la misma dirección.

Similitud coseno = 0 → los vectores son ortogonales.

Similitud coseno = -1 → los vectores apuntan en sentido contrario.

Similitud coseno





"Se utiliza para evaluar la dirección de dos vectores"


$$\cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$

Machine Learning para NLP

Modelo de clasificación de texto



Modelo de clasificación, Naïve Bayes



Modelo de clasificación Naïve Bayes

¿Por qué es "Naive" (Ingenuo)?

Porque asume que cada palabra en una frase es **independiente** de las demás. No le importa el orden; solo le importa si la palabra está ahí.

¿Cómo funciona?

Calcula la probabilidad de que un texto pertenezca a una categoría basándose en las palabras que contiene.

- *Ejemplo:* Si la palabra "Descuento" aparece mucho en correos marcados como "Spam", cuando llegue un correo nuevo con esa palabra, la probabilidad de que sea "Spam" sube.

Modelo de clasificación Naïve Bayes



$$p(\mathbf{N}) = 0.67$$

$$p(\text{Dear} | \mathbf{N}) = 0.47$$

$$p(\text{Friend} | \mathbf{N}) = 0.29$$

$$p(\text{Lunch} | \mathbf{N}) = 0.18$$

$$p(\text{Money} | \mathbf{N}) = 0.06$$

$$p(\mathbf{N}) \times p(\text{Dear} | \mathbf{N}) \times p(\text{Friend} | \mathbf{N}) = 0.09$$



$$p(\mathbf{S}) = 0.33$$

$$p(\text{Dear} | \mathbf{S}) = 0.29$$

$$p(\text{Friend} | \mathbf{S}) = 0.14$$



$$p(\text{Lunch} | \mathbf{S}) = 0.00$$

$$p(\text{Money} | \mathbf{S}) = 0.57$$

$$p(\mathbf{S}) \times p(\text{Dear} | \mathbf{S}) \times p(\text{Friend} | \mathbf{S}) = 0.01$$

Modelo de clasificación Naïve Bayes

Suavizado de Laplace




Naive Bayes Multinomial

Variante específica para texto.

Mientras que el Naive Bayes básico solo mira si la palabra *aparece o no*, el **Multinomial** cuenta **cuántas veces** aparece.

Representaciones y modelos de tipo “Bolsa de palabras” (BOW)




Cualquier modelo o representación (vectorización) de texto en donde el resultado no se modifique con el orden de las palabras es un modelo o representación BOW.

CountVector, OHE, TF-IDF son ejemplos de representaciones BOW
Naïve Bayes es un ejemplo de clasificador tipo BOW



Colab





NLP Clásico vs NLP + DL vs LLMs



NLP Clásico

- 1.- Texto
- 2.- Tokenización
- 3.- Stop words removal
- 4.- Stemming / Lemmatization
- 5.- Vectorización (BoW, TF-IDF)
- 6.- Modelo ML

NLP + DL

- 1.- Texto
- 2.- Tokenización
- 3.- Subword tokenization (BPE, WordPiece)
- 4.- Embeddings
- 5.- Modelo

LLMs

- 1.- Texto
- 2.- Tokenizer (BPE / WordPiece / SentencePiece)
- 3.- IDs de tokens
- 4.- Transformer