

NLP

Word Embeddings


Docente:

Josselyn Ordóñez

emails: josselynsofia@gmail.com

Preprocesamiento de texto

[LINK GLOSARIO](#)



TF-IDF (Term frequency-Inverse document frequency)



Se utiliza como indicador de cuán importante es una palabra (término) en un documento.


$$\text{TF-IDF}_{(n,d)} = \text{TF}_{(n,d)} \times \text{IDF}_{(n)}$$

Peso de un término (n) en un documento (d)

Frecuencia de aparición de un término (n) en un documento (d)

Factor IDF de un término (n)

Proceso en el cual una oración o documento es segmentado en términos individuales. Una vez finalizada la segmentación cada término único es referenciado mediante un token.



Problemas con CountVectorizer/OHE/TF-IDF



Textos de significado similar pueden ser “ortogonales”


Estoy viajando en colectivo

Voy arriba del bus

Ortogonal -> Similaridad coseno = 0

La dimensión de los vectores depende del tamaño del vocabulario


No aprovechamos la dimensionalidad



Embeddings




Un embedding es una representación densa de palabras en un espacio vectorial continuo.



Propiedades buscadas:

- 1. Representación compacta***
- 2. Similitud semántica***
- 3. Comprensión de contexto***

Atributos como dimensiones



Atributos como dimensiones



	Dulzor	Tamaño	Rojo	Tropical	Circular
	4	3	10	3	3
	10	10	0	10	6
	3	1	0	2	10
	5	5	10	2	7
	7	7	0	7	2

Evolución de embeddings




Word2Vec (2013)

- **Creador:** Google
- **Hito:** Es el momento en que los vectores se vuelven "famosos".
- **Aporte:** Introducen las arquitecturas **CBOW** y **Skip-gram**.

Fast Text (2016)

- **Creador:** Facebook
- **Hito:** Resuelven el problema de las palabras desconocidas.
- **Aporte:** n-grams de caracteres.



Glove (2014)

- **Creador:** Universidad de Stanford
- **Hito:** Incorpora estadísticas globales de todo el texto.
- **Aporte:** matriz de co-ocurrencias de todo el corpus.

ELMo / BERT (2018+)

- **Creador:** Allen Institute (ELMo) y Google (BERT)
- **Hito:** embeddings dinámicos.
- **Aporte:** pasamos de word embeddings a contextual embeddings.



Es una técnica publicada por **Google en 2013** que revolucionó la Inteligencia Artificial. Su gran descubrimiento fue que podíamos enseñarles a las máquinas el **significado** de las palabras simplemente haciéndolas "leer" mucho texto, sin diccionarios.

Antes: Las palabras eran etiquetas aisladas (IDs).

Con Word2Vec: Las palabras son **vectores** (flechas o coordenadas) en un espacio de muchas dimensiones.

La hipótesis distributiva: "Conocerás a una palabra por las compañías que tiene"


Word Embeddings



Las palabras que tienen un significado similar tendrán una representación similar como embeddings

<http://projector.tensorflow.org/>

Veremos una proyección en 3 dimensiones de los embeddings multidimensionales.



GloVe y fastText



Embeddings pre-entrenados basados en diferentes enfoques:

GloVe



Tokenización basada en palabras



Entrenado con textos de Wikipedia, Common Crawl y GigaWord 5



Se basa en calcular la matriz de co-ocurrencia de palabras y estimar el cociente de probabilidad de aparición.

fastText



Tokenización basada en N-Grams de caracteres (3 a 6). Mejora la interpretación de sufijos y prefijos



Entrenado con una colección de 8 corpus (portales de noticias, reviews, Wikipedia)



Basado en word2vec (CBOW/Skip-Gram)



Puede crear un embedding de una palabra que nunca vió

Matriz de co-ocurrencia



Obtención del corpus: Se reunió las letras de sus canciones desde fuentes en línea, como letras.top y Buenamusica.com.

Preprocesamiento del texto:

- Convertir todo el texto a minúsculas.
- Eliminar signos de puntuación.
- Tokenizar el texto para dividirlo en palabras individuales.
- Eliminar palabras vacías comunes en español, como "el", "la", "y", etc.

Cálculo de frecuencias: Contar la frecuencia de cada palabra y seleccionar las 10 más comunes.

Construcción de la matriz de co-ocurrencia:

- Definir una ventana de contexto de 5 palabras alrededor de cada término.
- Contar cuántas veces cada par de palabras apareció dentro de la misma ventana.

	amor	vida	luz	sol	piel	alma	tiempo	ojos	corazón	cielo
amor	0	15	12	10	8	14	9	11	13	10
vida	15	0	11	9	7	13	8	10	12	9
luz	12	11	0	8	6	10	7	9	11	8
sol	10	9	8	0	5	9	6	8	10	7
piel	8	7	6	5	0	7	4	6	8	5
alma	14	13	10	9	7	0	8	11	13	10
tiempo	9	8	7	6	4	8	0	7	9	6
ojos	11	10	9	8	6	11	7	0	12	9
corazón	13	12	11	10	8	13	9	12	0	10
cielo	10	9	8	7	5	10	6	9	10	0

GloVe y fastText



Embeddings pre-entrenados basados en diferentes enfoques:

GloVe



Tokenización basada en palabras



Entrenado con textos de Wikipedia, Common Crawl y GigaWord 5



Se basa en calcular la matriz de co-ocurrencia de palabras y estimar el cociente de probabilidad de aparición.

fastText



Tokenización basada en N-Grams de caracteres (3 a 6). Mejora la interpretación de sufijos y prefijos



Entrenado con una colección de 8 corpus (portales de noticias, reviews, Wikipedia)



Basado en word2vec (CBOW/Skip-Gram)




Puede crear un embedding de una palabra que nunca vió



"Subsecuencia de N elementos de una secuencia dada"

Otra forma de agrupar las palabras distinto a word2vec ($N=1$, unigram) en donde se busca aumentar el poder de generalización y a su vez poder hacer más variado el vocabulario.



Character-level unigrams

<u>Text</u>	<u>Token Sequence</u>	<u>Token Value</u>
Dogs	1	D
Dogs	2	o
Dogs	3	g
Dogs	4	s

Character-level bigrams

<u>Text</u>	<u>Token Sequence</u>	<u>Token Value</u>
Dogs	1	Do
Dogs	2	og
Dogs	3	gs

Character-level trigrams

<u>Text</u>	<u>Token Sequence</u>	<u>Token Value</u>
Dogs	1	Dog
Dogs	2	ogs

N-gramas (por palabras)



Todas las hojas son del viento

Unigramas

“todas”

“las”

“hojas”

“son”

“del”

“viento”

Bigramas

“todas las”

“las hojas”

“hojas son”

“son del”

“del viento”

Trigramas

“Todas las hojas”

“las hojas son”

“hojas son del”

“son del viento”

N-gramas (por caracteres)



Todas las hojas son del viento

Unigramas

"t"

"o"

"d"

"a"

"s"

"..."

Bigramas

"to"

"od"

"da"

"as"

"..."

Trigramas

"Tod"

"oda"

"das"

"as "

"..."

En esta idea se basa fastText

Operaciones con Embeddings: tests de analogías




Una forma de testear la calidad de embeddings es probar su desempeño en tests de analogías:

París es a Francia lo que Madrid es a España.

Madrid y París corresponden a España y Francia

$$\overrightarrow{Paris} - \overrightarrow{Francia} \approx \overrightarrow{Madrid} - \overrightarrow{España}$$

$$\text{simcos}(\overrightarrow{Paris} - \overrightarrow{Francia}, \overrightarrow{Madrid} - \overrightarrow{España}) \approx 1$$





Colab 2.a





Intervalo

CBOW (Continuous Bag of Words)



Adivinando la palabra por su contexto

El modelo recibe las palabras de alrededor (las "pistas") e intenta predecir cuál es la palabra que falta en el centro.

El _____ maúlla en el tejado.

Características clave:


- **Muchos a Uno:** Varias palabras de entrada → Una palabra de salida.
- **Velocidad:** Es muy rápido de entrenar.
- **Uso ideal:** Funciona mejor cuando tenemos mucha cantidad de texto y queremos capturar el significado general de palabras muy comunes.




¿Cómo podemos crear nuestros word Embeddings?



Aprendiendo (con redes neuronales) vectores para cada palabra que maximicen la relación entre las palabras de contexto y la palabra objetivo. Esto es lo que se implementó en la librería **word2vec**.



$$\frac{1}{T} \sum_{t=1}^T \log p(w_t | w_{t-c}, \dots, w_{t+c})$$




$$\frac{1}{T} \sum_{t=1}^T \sum_{-c \leq j \leq c, j \neq 0} \log p(w_{t+j} | w_t)$$

Se utiliza **OneHotEncoding** como representación del texto a la entrada del modelo


Continuous Bag of Words Model (CBOW)



Utiliza como entrada el contexto de la palabra objetivo (palabras a izquierda y derecha de ella). El tamaño de la ventana determina cuántas palabras se tomarán para contextualizar el embedding.




CBOW



Continuous Bag of Words Model (CBOW)




Utiliza como entrada el contexto de la palabra objetivo (palabras a izquierda y derecha de ella). El tamaño de la ventana determina cuántas palabras se tomarán para contextualizar el embedding.




CBOW - Entrenamiento

[LINK](#)



Para entrenar necesitamos tener el vocabulario del corpus y las sentencias organizadas por el tamaño de la ventana de entrada.

Los embeddings de cada palabra son el embedding promedio de todas las veces que se utilizó en el corpus.




```
cbow = Sequential()
cbow.add(Embedding(input_dim=vocab_size, output_dim=embed_size, input_length=window_size*2))
cbow.add(Lambda(lambda x: K.mean(x, axis=1), output_shape=(embed_size,)))
cbow.add(Dense(vocab_size, activation='softmax'))
cbow.compile(loss='categorical_crossentropy', optimizer='rmsprop')
```

CBOW - Entrenamiento



Con tan solo un corpus de 12425 palabras distintas y embedding de 100 dimensiones hay que entrenar **2.5 Millones de parámetros**

Layer (type)	Output Shape	Param #
embedding_1 (Embedding)	(None, 4, 100)	1242500
lambda_1 (Lambda)	(None, 100)	0
dense_1 (Dense)	(None, 12425)	1254925
Total params: 2,497,425		
Trainable params: 2,497,425		
Non-trainable params: 0		






Adivinando el contexto por una palabra

Al contrario de CBOW, este modelo intenta predecir las palabras que rodean (contexto) a una palabra objetivo. Se divide el output como pares [target, context]

Características clave:


- **Uno a Muchos:** Una palabra de entrada → Varias palabras de contexto estimadas.
- **Precisión:** Es más lento que CBOW, pero mucho más preciso para palabras que no aparecen con frecuencia (palabras raras).
- **Uso ideal:** Es el preferido cuando el vocabulario es complejo o los datos no son gigantescos.



Skip-Gram



Al contrario de CBOW, este modelo intenta predecir las palabras que rodean (contexto) a una palabra objetivo. Se divide el output como pares [target, context]



Skip-Gram - Entrenamiento

[LINK](#)




Por cada par [target, context] el sistema determina si las palabras tiene significado en contexto (1) o no lo tiene (0), buscando así acercar las palabras que tienen significado juntas (que se espera que estén juntas en el texto)

```
word_model = Sequential()
word_model.add(Embedding(vocab_size, embed_size,
                        embeddings_initializer="glorot_uniform",
                        input_length=1))
word_model.add(Reshape((embed_size, )))

context_model = Sequential()
context_model.add(Embedding(vocab_size, embed_size,
                           embeddings_initializer="glorot_uniform",
                           input_length=1))
context_model.add(Reshape((embed_size, )))

model = Sequential()
model.add(Merge([word_model, context_model], mode="dot"))
model.add(Dense(1, kernel_initializer="glorot_uniform", activation="sigmoid"))
```




Skip-Gram - Entrenamiento



Skip-Gram requiere más datos para lograr un buen resultado pero obtiene más información sobre el contexto del corpus en sus embeddings.

Layer (type)	Output Shape	Param #
merge_2 (Merge)	(None, 1)	0
dense_3 (Dense)	(None, 1)	2
Total params: 2,485,002		
Trainable params: 2,485,002		
Non-trainable params: 0		



Negative sampling

[LINK](#)



En SkipGram/CBOW la cantidad de parámetros a entrenar en la softmax es enorme:

$Parametros = vocab_size * embedding_size \rightarrow \text{millones de parámetros}$

Vanilla
Skip-Gram

W_output (old)	Learning R.	grad_W_output	=	W_output (new)																																																																																																			
<table><tr><td>-0.560</td><td>0.340</td><td>0.160</td></tr><tr><td>-0.910</td><td>-0.440</td><td>1.560</td></tr><tr><td>-1.210</td><td>-0.130</td><td>-1.320</td></tr><tr><td>1.670</td><td>-0.150</td><td>-1.030</td></tr><tr><td>1.720</td><td>-1.460</td><td>0.730</td></tr><tr><td>0.000</td><td>1.390</td><td>-0.120</td></tr><tr><td>-0.060</td><td>1.520</td><td>-0.790</td></tr><tr><td>0.800</td><td>1.850</td><td>-1.670</td></tr><tr><td>-1.370</td><td>1.320</td><td>-0.480</td></tr><tr><td>0.670</td><td>1.990</td><td>-1.850</td></tr><tr><td>-1.520</td><td>-1.740</td><td>-1.860</td></tr></table>	-0.560	0.340	0.160	-0.910	-0.440	1.560	-1.210	-0.130	-1.320	1.670	-0.150	-1.030	1.720	-1.460	0.730	0.000	1.390	-0.120	-0.060	1.520	-0.790	0.800	1.850	-1.670	-1.370	1.320	-0.480	0.670	1.990	-1.850	-1.520	-1.740	-1.860	0.05	<table><tr><td>0.064</td><td>0.071</td><td>-0.014</td></tr><tr><td>0.098</td><td>0.015</td><td>0.063</td></tr><tr><td>0.069</td><td>0.089</td><td>0.045</td></tr><tr><td>0.014</td><td>0.085</td><td>0.079</td></tr><tr><td>-0.021</td><td>0.067</td><td>0.071</td></tr><tr><td>-0.098</td><td>-0.088</td><td>0.091</td></tr><tr><td>-0.072</td><td>-0.078</td><td>-0.089</td></tr><tr><td>0.046</td><td>-0.079</td><td>-0.053</td></tr><tr><td>-0.049</td><td>-0.087</td><td>0.025</td></tr><tr><td>-0.060</td><td>0.092</td><td>0.042</td></tr><tr><td>0.074</td><td>0.050</td><td>0.070</td></tr></table>	0.064	0.071	-0.014	0.098	0.015	0.063	0.069	0.089	0.045	0.014	0.085	0.079	-0.021	0.067	0.071	-0.098	-0.088	0.091	-0.072	-0.078	-0.089	0.046	-0.079	-0.053	-0.049	-0.087	0.025	-0.060	0.092	0.042	0.074	0.050	0.070		<table><tr><td>-0.563</td><td>0.336</td><td>0.161</td></tr><tr><td>-0.915</td><td>-0.441</td><td>1.557</td></tr><tr><td>-1.213</td><td>-0.134</td><td>-1.322</td></tr><tr><td>1.669</td><td>-0.154</td><td>-1.034</td></tr><tr><td>1.721</td><td>-1.463</td><td>0.726</td></tr><tr><td>0.005</td><td>1.394</td><td>-0.125</td></tr><tr><td>-0.056</td><td>1.524</td><td>-0.786</td></tr><tr><td>0.798</td><td>1.854</td><td>-1.667</td></tr><tr><td>-1.368</td><td>1.324</td><td>-0.481</td></tr><tr><td>0.673</td><td>1.985</td><td>-1.852</td></tr><tr><td>-1.524</td><td>-1.743</td><td>-1.864</td></tr></table>	-0.563	0.336	0.161	-0.915	-0.441	1.557	-1.213	-0.134	-1.322	1.669	-0.154	-1.034	1.721	-1.463	0.726	0.005	1.394	-0.125	-0.056	1.524	-0.786	0.798	1.854	-1.667	-1.368	1.324	-0.481	0.673	1.985	-1.852	-1.524	-1.743	-1.864
-0.560	0.340	0.160																																																																																																					
-0.910	-0.440	1.560																																																																																																					
-1.210	-0.130	-1.320																																																																																																					
1.670	-0.150	-1.030																																																																																																					
1.720	-1.460	0.730																																																																																																					
0.000	1.390	-0.120																																																																																																					
-0.060	1.520	-0.790																																																																																																					
0.800	1.850	-1.670																																																																																																					
-1.370	1.320	-0.480																																																																																																					
0.670	1.990	-1.850																																																																																																					
-1.520	-1.740	-1.860																																																																																																					
0.064	0.071	-0.014																																																																																																					
0.098	0.015	0.063																																																																																																					
0.069	0.089	0.045																																																																																																					
0.014	0.085	0.079																																																																																																					
-0.021	0.067	0.071																																																																																																					
-0.098	-0.088	0.091																																																																																																					
-0.072	-0.078	-0.089																																																																																																					
0.046	-0.079	-0.053																																																																																																					
-0.049	-0.087	0.025																																																																																																					
-0.060	0.092	0.042																																																																																																					
0.074	0.050	0.070																																																																																																					
-0.563	0.336	0.161																																																																																																					
-0.915	-0.441	1.557																																																																																																					
-1.213	-0.134	-1.322																																																																																																					
1.669	-0.154	-1.034																																																																																																					
1.721	-1.463	0.726																																																																																																					
0.005	1.394	-0.125																																																																																																					
-0.056	1.524	-0.786																																																																																																					
0.798	1.854	-1.667																																																																																																					
-1.368	1.324	-0.481																																																																																																					
0.673	1.985	-1.852																																																																																																					
-1.524	-1.743	-1.864																																																																																																					
(11X3)		(11X3)		(11X3)																																																																																																			

Negative
Sampling

W_output (old)	Learning R.	grad_W_output	=	W_output (new)																																																																		
<table><tr><td>-0.560</td><td>0.340</td><td>0.160</td></tr><tr><td>-0.910</td><td>-0.440</td><td>1.560</td></tr><tr><td>-1.210</td><td>-0.130</td><td>-1.320</td></tr><tr><td>1.670</td><td>-0.150</td><td>-1.030</td></tr><tr><td>1.720</td><td>-1.460</td><td>0.730</td></tr><tr><td>0.000</td><td>1.390</td><td>-0.120</td></tr><tr><td>-0.060</td><td>1.520</td><td>-0.790</td></tr><tr><td>0.800</td><td>1.850</td><td>-1.670</td></tr><tr><td>-1.370</td><td>1.320</td><td>-0.480</td></tr><tr><td>0.670</td><td>1.990</td><td>-1.850</td></tr><tr><td>-1.520</td><td>-1.740</td><td>-1.860</td></tr></table>	-0.560	0.340	0.160	-0.910	-0.440	1.560	-1.210	-0.130	-1.320	1.670	-0.150	-1.030	1.720	-1.460	0.730	0.000	1.390	-0.120	-0.060	1.520	-0.790	0.800	1.850	-1.670	-1.370	1.320	-0.480	0.670	1.990	-1.850	-1.520	-1.740	-1.860	0.05 ×	Not computed!		<table><tr><td>-0.560</td><td>0.340</td><td>0.160</td></tr><tr><td>-0.910</td><td>-0.440</td><td>1.560</td></tr><tr><td>-1.210</td><td>-0.130</td><td>-1.320</td></tr><tr><td>1.670</td><td>-0.150</td><td>-1.030</td></tr><tr><td>1.720</td><td>-1.460</td><td>0.730</td></tr><tr><td>0.000</td><td>1.390</td><td>-0.120</td></tr><tr><td>-0.060</td><td>1.520</td><td>-0.790</td></tr><tr><td>0.798</td><td>1.849</td><td>-1.672</td></tr><tr><td>-1.366</td><td>1.318</td><td>-0.477</td></tr><tr><td>0.667</td><td>1.985</td><td>-1.847</td></tr><tr><td>-1.523</td><td>-1.744</td><td>-1.858</td></tr></table>	-0.560	0.340	0.160	-0.910	-0.440	1.560	-1.210	-0.130	-1.320	1.670	-0.150	-1.030	1.720	-1.460	0.730	0.000	1.390	-0.120	-0.060	1.520	-0.790	0.798	1.849	-1.672	-1.366	1.318	-0.477	0.667	1.985	-1.847	-1.523	-1.744	-1.858
-0.560	0.340	0.160																																																																				
-0.910	-0.440	1.560																																																																				
-1.210	-0.130	-1.320																																																																				
1.670	-0.150	-1.030																																																																				
1.720	-1.460	0.730																																																																				
0.000	1.390	-0.120																																																																				
-0.060	1.520	-0.790																																																																				
0.800	1.850	-1.670																																																																				
-1.370	1.320	-0.480																																																																				
0.670	1.990	-1.850																																																																				
-1.520	-1.740	-1.860																																																																				
-0.560	0.340	0.160																																																																				
-0.910	-0.440	1.560																																																																				
-1.210	-0.130	-1.320																																																																				
1.670	-0.150	-1.030																																																																				
1.720	-1.460	0.730																																																																				
0.000	1.390	-0.120																																																																				
-0.060	1.520	-0.790																																																																				
0.798	1.849	-1.672																																																																				
-1.366	1.318	-0.477																																																																				
0.667	1.985	-1.847																																																																				
-1.523	-1.744	-1.858																																																																				
(11X3)		(11X3)		(11X3)																																																																		

Positive sample, w_o

0.031	0.030	0.041
-------	-------	-------

Negative sample, k=1

-0.090	0.031	-0.065
--------	-------	--------

Negative sample, k=2

0.056	0.098	-0.061
-------	-------	--------

Negative sample, k=3

0.069	0.084	-0.044
-------	-------	--------

En cada iteración se observa la palabras [target, contexto] y "K" palabras aleatorias del corpus.

El objetivo es optimizar cómputo aproximando la softmax. Además funciona como regularización. Para corpus pequeños, el muestreo debe ser mayor.

Visualizar embeddings en baja dimensionalidad:

[LINK](#)



t-SNE (t-distributed stochastic neighbor embedding)



Técnica de reducción de dimensionalidad no-lineal (a diferencia de PCA).




Intenta reproducir en baja dimensionalidad, la localidad de los datos en alta dimensionalidad.



Es estocástica, a priori los resultados no se repiten.



Por su carácter estocástico es sólo recomendable como herramienta de visualización y exploratoria.





Intervalo

Gensim - Doc2Vec paragraph embeddings

[LINK](#)



Utilizaremos esta librería que nos facilita generar embeddings tipo Skip-Gram o CBOW de nuestros corpus



- Librería de Python
- Existe desde 2009 y nació originalmente para topic modelling
- Muy popular y muy simple de utilizar



Colab 2.b





Crear sus propios vectores con Gensim basado en lo visto en clase con otro dataset.

Probar términos de interés y explicar similitudes en el espacio de embeddings.

Intentar plantear y probar tests de analogías. Graficar los embeddings resultantes.

Sacar conclusiones.



Algunos recursos para descargar corpora de texto



[Project Gutenberg](#)

Compilación de literatura completa de dominio público principalmente en inglés.

[Textos.info](#)

Compilación de literatura completa de dominio público en español.



Google
BERT

¿Qué cambió? El modelo ya no lee palabra por palabra de forma aislada. Mira la frase **entera**.

Innovación: El "Embedding" ya no se busca en una tabla fija; se **calcula en tiempo real** dependiendo de las palabras vecinas.



Sentence embeddings: ¿Cómo representamos una idea completa?

No es solo sumar palabras: No basta con sumar los vectores de "No", "es", "bueno". El orden y la estructura importan.

¿Qué son? Son vectores que representan el significado global de una oración o un párrafo entero.

Embeddings multimodales



¿Y si usamos el **mismo mapa para palabras y para fotos**?

¿Cómo funciona? El modelo se entrena con millones de imágenes y sus leyendas. Aprende que el vector de la foto de un perro debe estar en el mismo lugar que el vector de la palabra "perro".



Recomendaciones

Buscadores

Base de LLMs



Gemini

