


NLP

CNN para NLP

Docente:
MSc. Fernando Silva

email: fernandosilva.clases@gmail.com


Modelo de clasificación de texto



Representación de Secuencias



Para realizar tareas de NLP con Deep Learning, necesitamos representaciones vectoriales que capten de manera más precisa el significado y las relaciones entre palabras; es decir, **necesitamos embeddings**.




Word representation (usualmente embeddings)


Secuencia de *tokens*

Texto (*input*)

Representación de Secuencias




Representación de Secuencias



One-Hot Encoding



Empecemos con algo básico,
representación vectorial **One Hot Vector**



Alta dimensionalidad. No generalizan. Ignoran el contexto


Representación por One-Hot Encoding



~100K columns

	good	movie	very	a	did	like
very →	0	0	1	0	0	0
+						
good →	1	0	0	0	0	0
+						
movie →	0	1	0	0	0	0
=						
very good movie →	1	1	1	0	0	0

Representación por BoW



https://github.com/FIUBA-Posgrado-Inteligencia-Artificial/procesamiento_lenguaje_natural/blob/jul_2026/Clase%205/BOW.ipynb

Representación por Matriz de Co-ocurrencia



Una vez mi papá vió un **borochi** cuando fue a Santa Cruz.

...podemos ver al **borochi** comiendo unas frutas silvestres...

Actualmente muchos ganaderos cazan al **borochi** por verlo como una amenaza.

¿Qué es el **borochi**?



*“You shall know a
word by the
company it keep”
Firth, 1957*

Representación por Matriz de Co-ocurrencia



¿Cómo podemos hacer esto computacionalmente?

1º Contar las palabras en el contexto de “Y”.

2º Ver qué otras palabras ocurren en estos contextos.

4 palabras a la izquierda 4 palabras a la derecha

... por eso el pollo **frito** es comida rápida que...

Representación por Matriz de Co-ocurrencia



context words:

4 words to the left +

4 words to the right


is traditionally followed by **cherry** pie, a traditional dessert
often mixed, such as **strawberry** rhubarb pie. Apple pie
computer peripherals and personal **digital** assistants. These devices usually
a computer. This includes **information** available on the internet

	aardvark	...	computer	data	result	pie	sugar	...
cherry	0	...	2	8	9	442	25	...
strawberry	0	...	0	0	1	60	19	...
digital	0	...	1670	1683	85	5	4	...
information	0	...	3325	3982	378	5	13	...

Representación por Embedding




~300 columnas





Las redes neuronales que vimos hasta ahora reciben como entrada vectores de tamaño fijo...

Idea 1: Sliding window de tamaño N (CNN de 1D)





- En vez de píxeles de imágenes, la entrada en tareas de NLP son oraciones o documentos representados como una matriz.
- De esta matrix, cada fila corresponde a un token, típicamente un palabra ó un caracter. Es decir cada fila es un vector que representa una palabra.
- Estos vectores (típicamente) son **word embeddings** (**word2vec** ó **GloVe**) ó **one-hot vectors**.

CNN para Secuencias, Conv1D



Padding = 0

tentative	0.2	0.1	-0.3	0.4
deal	0.5	0.2	-0.3	-0.1
reached	-0.1	-0.3	-0.2	0.4
to	0.3	-0.3	0.1	0.1
keep	0.2	-0.3	0.4	0.2
government	0.1	0.2	-0.1	-0.1
open	-0.4	-0.4	0.2	0.3

t,d,r	-1.0
d,r,t	-0.5
r,t,k	-3.6
t,k,g	-0.2
k,g,o	0.3

Apply a **filter** (or **kernel**) of size 3

3	1	2	-3
-1	2	1	-3
1	1	-1	1

CNN para Secuencias, Conv1D



Padding = 1

$\emptyset$	0.0	0.0	0.0	0.0
tentative	0.2	0.1	-0.3	0.4
deal	0.5	0.2	-0.3	-0.1
reached	-0.1	-0.3	-0.2	0.4
to	0.3	-0.3	0.1	0.1
keep	0.2	-0.3	0.4	0.2
government	0.1	0.2	-0.1	-0.1
open	-0.4	-0.4	0.2	0.3
$\emptyset$	0.0	0.0	0.0	0.0

$\emptyset, t, d$	-0.6
t, d, r	-1.0
d, r, t	-0.5
r, t, k	-3.6
t, k, g	-0.2
k, g, o	0.3
$g, o, \emptyset$	-0.5

Apply a **filter (or kernel)** of size 3

3	1	2	-3
-1	2	1	-3
1	1	-1	1

[https://github.com/FIUBA-Posgrado-Inteligencia-Artificial/procesamiento_lenguaje_natural/blob/jul_2026/Clase%205/CNN para Secuencias%2C Co nv1D.ipynb](https://github.com/FIUBA-Posgrado-Inteligencia-Artificial/procesamiento_lenguaje_natural/blob/jul_2026/Clase%205/CNN_para_Secuencias%2C_Co nv1D.ipynb)

CNN para Secuencias, Conv1D



Padding = 0, 3 Kernels

$\emptyset$	0.0	0.0	0.0	0.0
tentative	0.2	0.1	-0.3	0.4
deal	0.5	0.2	-0.3	-0.1
reached	-0.1	-0.3	-0.2	0.4
to	0.3	-0.3	0.1	0.1
keep	0.2	-0.3	0.4	0.2
government	0.1	0.2	-0.1	-0.1
open	-0.4	-0.4	0.2	0.3
$\emptyset$	0.0	0.0	0.0	0.0

$\emptyset, t, d$	-0.6	0.2	1.4
t, d, r	-1.0	1.6	-1.0
d, r, t	-0.5	-0.1	0.8
r, t, k	-3.6	0.3	0.3
t, k, g	-0.2	0.1	1.2
k, g, o	0.3	0.6	0.9
$g, o, \emptyset$	-0.5	-0.9	0.1

Apply 3 filters of size 3

3	1	2	-3
-1	2	1	-3
1	1	-1	1

1	0	0	1
1	0	-1	-1
0	1	0	1

1	-1	2	-1
1	0	-1	3
0	2	2	1

CNN para Secuencias, Conv1D



Padding = 0, 3 Kernels, Max Pooling

$\emptyset$	0.0	0.0	0.0	0.0
tentative	0.2	0.1	-0.3	0.4
deal	0.5	0.2	-0.3	-0.1
reached	-0.1	-0.3	-0.2	0.4
to	0.3	-0.3	0.1	0.1
keep	0.2	-0.3	0.4	0.2
government	0.1	0.2	-0.1	-0.1
open	-0.4	-0.4	0.2	0.3
$\emptyset$	0.0	0.0	0.0	0.0

$\emptyset, t, d$	-0.6	0.2	1.4
t, d, r	-1.0	1.6	-1.0
d, r, t	-0.5	-0.1	0.8
r, t, k	-3.6	0.3	0.3
t, k, g	-0.2	0.1	1.2
k, g, o	0.3	0.6	0.9
$g, o, \emptyset$	-0.5	-0.9	0.1

max p	0.3	1.6	1.4
-------	-----	-----	-----

Apply 3 filters of size 3

3	1	2	-3
-1	2	1	-3
1	1	-1	1

1	0	0	1
1	0	-1	-1
0	1	0	1

1	-1	2	-1
1	0	-1	3
0	2	2	1

CNN para Secuencias, Arquitectura




From:


Zhang and Wallace
(2015) A Sensitivity
Analysis of (and
Practitioners' Guide
to) Convolutional
Neural Networks for
Sentence
Classification

<https://arxiv.org/pdf/1510.03820.pdf>

(follow on paper, not
famous, but a nice picture)



CNN para Secuencias, Arquitectura



[https://github.com/FIUBA-Posgrado-Inteligencia-Artificial/procesamiento_lenguaje_natural/blob/jul_2026/C_lase%205/CNN_para_Secuencias%2C_Arquitectura_CNN%20\(1\).ipynb](https://github.com/FIUBA-Posgrado-Inteligencia-Artificial/procesamiento_lenguaje_natural/blob/jul_2026/C_lase%205/CNN_para_Secuencias%2C_Arquitectura_CNN%20(1).ipynb)

CNN para Secuencias

CNN funciona pero no es lo más óptimo para NLP:

- **Contexto largo pobre:** solo capturan relaciones locales.
- **Sin atención global:** no modelan bien relaciones entre palabras lejanas.



El **libro** que compré en la tienda que está cerca de la universidad que visitamos el año pasado es **interesante**.

Una CNN procesa en ventanas pequeñas, por lo que pierde esa relación a larga distancia. **Necesitamos otro mecanismo.**

Mecanismo de atención



En general, un mecanismo de atención es una transformación de secuencias de embeddings a secuencias de embeddings de forma ponderada y paralela.

Existen varios tipos pero las operaciones fundamentales consisten en:

- El cálculo un vector de pesos/scores de atención .
- La construcción de un vector ponderado que es fácilmente paralelizable a lo largo del tamaño de la secuencia.

¡La degradación del gradiente es independiente del tamaño de la secuencia!


Pero se debe fijar el tamaño máximo de secuencia a procesar.

A futuro veremos que el mecanismo de **self-attention** es el que utilizan las arquitecturas **transformer**.

Mecanismos de atención



Atención para Encoding-decoding



Self-attention (transformers)

Each vector receives three representations ("roles")

$$[W_Q] \times \begin{bmatrix} \text{green} \\ \text{green} \\ \text{green} \end{bmatrix} = \begin{bmatrix} \text{blue} \\ \text{blue} \\ \text{blue} \end{bmatrix}$$

Query: vector from which the attention is looking

"Hey there, do you have this information?"

$$[W_K] \times \begin{bmatrix} \text{green} \\ \text{green} \\ \text{green} \end{bmatrix} = \begin{bmatrix} \text{yellow} \\ \text{yellow} \\ \text{yellow} \end{bmatrix}$$


Key: vector at which the query looks to compute weights

"Hi, I have this information - give me a large weight!"

$$[W_V] \times \begin{bmatrix} \text{green} \\ \text{green} \\ \text{green} \end{bmatrix} = \begin{bmatrix} \text{red} \\ \text{red} \\ \text{red} \end{bmatrix}$$

Value: their weighted sum is attention output

"Here's the information I have!"



https://lena-voita.github.io/resources/lectures/seq2seq/transformer/encoder_self_attention.mp4