

NLP

Grandes Modelos de Lenguaje

MSc. Fernando Silva
fernandosilva.clases@gmail.com


Agenda



- Repaso Transformers
- Código Clase 7
- Limitaciones de los LLMs
- Adaptación de LLMs
- RAG
- Fine-tuning
- RLHF
- Actualidad y futuro de NLP

Repaso Transformers


Repaso, Transformers



Repaso, Transformers



Encoder:
Entiende y
representa el
significado de
un texto de
entrada.



Decoder:
Genera texto
nuevo basándose
en un contexto
previo.




Pre-training

El pretraining es el proceso de **entrenar un modelo de lenguaje desde cero sobre grandes volúmenes de texto no etiquetado**, con el objetivo de aprender representaciones generales del lenguaje mediante tareas auto-supervisadas.



Definimos objetivos para “lidar” con los datos no supervisados




Pre-training

El pretraining es el proceso de **entrenar un modelo de lenguaje desde cero sobre grandes volúmenes de texto no etiquetado**, con el objetivo de aprender representaciones generales del lenguaje mediante tareas auto-supervisadas.



Definimos objetivos para “lidiar” con los datos no supervisados




BERT (2019)

“Pre-training of Deep Bidirectional Transformers”

[LINK](#)

[LINK](#)

[LINK](#)



Su arquitectura se basa en stack de layers de transformers (encoders)

NSP: Se entrenó observando dos secuencias de entrada, su misión era determinar si la segunda secuencia estaba relacionada o no con la primera.

MLM: De forma aleatoria en cada inferencia se ocultó una palabra de cada secuencia (masked)

Utiliza la tokenización WordPiece


[Creado por Hugging Face/Google](#)

BERT (2019)

“Pre-training of Deep Bidirectional Transformers”



MLM




BERT (2019)

“Pre-training of Deep Bidirectional Transformers”



NSP





Link al Colab





LINK



Link al Colab



[LINK](#)






Link al Colab



LINK



Temperature en Softmax




$$\frac{e^{x_i}}{\sum e^{x_j}}$$

Traditional Softmax

$$\frac{e^{\frac{x_i}{T}}}{\sum e^{\frac{x_j}{T}}}$$

Temperature-adjusted
Softmax





Link al Colab




LINK




Estimated training cost and compute of select AI models

Source: Epoch, 2023 | Chart: 2024 AI Index report



Pre-training y Post-training




Limitaciones de los LLMs

Limitaciones de los LLMs



- ❖ Los LLMs parecen inteligentes... pero no entienden el mundo.
- ❖ Solo predicen la siguiente palabra.



$P(\text{siguiente palabra} \mid \text{contexto})$



On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? 🦜

Emily M. Bender*
ebender@uw.edu
University of Washington
Seattle, WA, USA

Angelina McMillan-Major
aymm@uw.edu
University of Washington
Seattle, WA, USA

Timnit Gebru*
timnit@blackinai.org
Black in AI
Palo Alto, CA, USA

Shmargaret Shmitchell
shmargaret.shmitchell@gmail.com
The Aether

On the Dangers of Stochastic Parrots:
Can Language Models Be Too Big? (2021)

Limitaciones de los LLMs, Alucinaciones



Una alucinación ocurre cuando un LLM produce una salida que no está respaldada por datos reales ni por su contexto de entrada, debido a que optimiza la probabilidad del texto en lugar de la veracidad.

¿Qué selección ganó el mundial el 2006? 



Italia

¿Qué dice la regla 5 del club Manzanas Futbol Club? 



La regla 5 es siempre llega puntual (*alucinación*)

Limitaciones de los LLMs, Alucinaciones



ChatGPT 3.5

How many r in strawberry

There are 2 r's in "strawberry."

Try harder

My apologies for the confusion earlier. There are actually 3 r's in "strawberry."

Can you please spell it out letter by letter?

Sure! Here's "strawberry" spelled out letter by letter:

S - T - R - A - W - B - E - R - R - Y

As you can see, there are indeed 2 r's.

That literally shows there are 3 R's. See this- stRawbeRRy

< 2/2 >

You're right, I see where the confusion is coming from! Let's look at it carefully:

- "strawberry" contains 3 r's: one in the middle (after the "t"), and two towards the end (before and after the "e").

Thanks for pointing that out!

Limitaciones de los LLMs, Es generalista, no un especialista



El modelo es generalista, no está adaptado a tareas específicas ni a un dominio concreto.

Clasifica este correo:
"Gana dinero rápido desde casa haciendo clic aquí" 



Este correo parece sospechoso y podría ser spam debido a su contenido.

No sigue formato, no da una respuesta clara (spam / no spam).



Alucinaciones

 Italia

¿Qué selección ganó el mundial el 2006? 

¿Qué dice la regla 5 del club Manzanitas Fútbol Club? 

 La regla 5 es siempre llega puntual (*alucinación*)

Solución: RAG (Retrieval-Augmented Generation)

Es generalista, no un especialista

Clasifica este correo:
"Gana dinero rápido desde casa haciendo clic aquí" 

 Este correo parece sospechoso y podría ser spam debido a su contenido.

Solución: Fine-tuning

Solución en ciertos escenarios: Prompting

Adaptación de LLMs

Adaptación de LLMs



Después del pretraining, un LLM puede adaptarse mediante técnicas que modifican sus pesos (post-training, como SFT, RLHF o DPO) o mediante técnicas que no modifican sus pesos (como prompting y RAG).

Adaptación sin entrenar

- Prompting (1)
- RAG (2)

Adaptación entrenando (Post-Training)

- SFT (3)
- Instruction Tuning
- RLHF (4)

Prompting

Definición

- ❖ Diseño de instrucciones para guiar al LLM.
- ❖ Define cómo usar el contexto recuperado.
- ❖ Reduce errores y hallucinations.

La idea es forzar al modelo a:

- ❖ Usar SOLO el contexto recuperado.
- ❖ No inventar información.
- ❖ Responder de forma precisa y estructurada.

Estructura típica de un prompt

Instrucciones:

Responde usando SOLO el contexto.
Si no está en el contexto, di "No sé".

Contexto:

En el club de MFC las reglas son ... la
regla 5 es no comer en la pista...reglas...

Pregunta:

Cual es la regla 5?

FEW SHOT, ONE SHOT

Instrucciones:

Responde usando SOLO el contexto.

Si no está en el contexto, di "No sé".

Contexto:

En el club de MFC las reglas son ... la regla 5 es no comer en la pista...reglas...

Pregunta:

Cual es la regla 3?

Respuesta:

No llegar tarde

Pregunta:

Cual es la regla 5?:

FEW SHOT, ONE SHOT

Instrucciones:

Responde usando SOLO el contexto.

Si no está en el contexto, di "No sé".

Contexto:

En el club de MFC las reglas son muy duras porque queremos disciplina. la regla 55 es que no puedes comer en el campo y la regla 5 es no comer en la pista. Importante saber esto si eres nuevo.

Pregunta:

Cual es la regla 3?

Respuesta:

En el club MFC la regla 3 es no llegar tarde

Pregunta:

Cual es la regla 2?

Respuesta:

En el club MFC la regla 2 es no venir en la madrugada

Pregunta:

FEW SHOT, TWO SHOT

Instrucciones:

Responde usando SOLO el contexto.

Si no está en el contexto, di "No sé".

Contexto:

En el club de MFC las reglas son ... la regla 5 es no comer en la pista...reglas...

Pregunta:

Cual es la regla 3?

Respuesta:

No llegar tarde

Pregunta:

Cual es la regla 6?

Respuesta:

No romper la raqueta

Pregunta:

Cual es la regla 5?:

Few-shot Prompting

Few-shot prompting

Prompt

We are going to be doing Entailment/ Contradiction reasoning applying the statute below:

§7703. Determination of marital status

(a) General rule

(1) the determination of whether an individual is married shall be made as of (...)

Premise: Alice and Bob got married on April 5th, 2012. Alice and Bob were legally separated under a decree of divorce on September 16th, 2017.

Hypothesis: Section 7703(a)(2) applies to Alice for the year 2012.

Answer: Contradiction

Example

Premise: Alice and Bob got married on April 5th, 2012. Bob died September 16th, 2017.

Hypothesis: Section 7703(a)(1) applies to Alice for the year 2012.

Answer:

Response

Entailment

Few-shot Prompting

Few-shot prompting

Prompt

We are going to be doing Entailment/ Contradiction reasoning applying the statute below:

§7703. Determination of marital status

(a) General rule

(1) the determination of whether an individual is married shall be made as of (...)

Premise: Alice and Bob got married on April 5th, 2012. Alice and Bob were legally separated under a decree of divorce on September 16th, 2017.

Hypothesis: Section 7703(a)(2) applies to Alice for the year 2012.

Answer: Contradiction

Example

Premise: Alice and Bob got married on April 5th, 2012. Bob died September 16th, 2017.

Hypothesis: Section 7703(a)(1) applies to Alice for the year 2012.

Answer:

Response

Entailment

Chain-of-Thought Prompting

Standard Prompting

Model Input

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: The answer is 11.

Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?

Model Output

A: The answer is 27. ❌

Chain-of-Thought Prompting

Model Input

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: Roger started with 5 balls. 2 cans of 3 tennis balls each is 6 tennis balls. $5 + 6 = 11$. The answer is 11.

Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?

Model Output

A: The cafeteria had 23 apples originally. They used 20 to make lunch. So they had $23 - 20 = 3$. They bought 6 more apples, so they have $3 + 6 = 9$. The answer is 9. ✅

Program-aided Language Prompting

Chain-of-Thought (Wei et al., 2022)

Input

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: Roger started with 5 tennis balls. 2 cans of 3 tennis balls each is 6 tennis balls. $5 + 6 = 11$. The answer is 11.

Q: The bakers at the Beverly Hills Bakery baked 200 loaves of bread on Monday morning. They sold 93 loaves in the morning and 39 loaves in the afternoon. A grocery store returned 6 unsold loaves. How many loaves of bread did they have left?

A: The bakers started with 200 loaves. They sold 93 in the morning and 39 in the afternoon. So they sold $93 + 39 = 132$ loaves. The grocery store returned 6 loaves. So they had $200 - 132 - 6 = 62$ loaves left.
The answer is 62.



Model Output

Program-aided Language models (this work)

Input

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: Roger started with 5 tennis balls.

`tennis_balls = 5`

`2 cans of 3 tennis balls each is`

`bought_balls = 2 * 3`

`tennis_balls`. The answer is

`answer = tennis_balls + bought_balls`

Q: The bakers at the Beverly Hills Bakery baked 200 loaves of bread on Monday morning. They sold 93 loaves in the morning and 39 loaves in the afternoon. A grocery store returned 6 unsold loaves. How many loaves of bread did they have left?

A: The bakers started with 200 loaves

`loaves_baked = 200`

`They sold 93 in the morning and 39 in the afternoon`

`loaves_sold_morning = 93`

`loaves_sold_afternoon = 39`

`The grocery store returned 6 loaves.`

`loaves_returned = 6`

The answer is

`answer = loaves_baked - loaves_sold_morning`
`- loaves_sold_afternoon + loaves_returned`

`>>> print(answer)`

74



Role Prompting

Role Based Prompting

A Role Prompt

You are
Shakespeare,
an English
writer.
Write me a
poem.



Model Output

Of lovers'
hearts and
passion's
fire...

Emotional Prompting

Original Prompt

Determine whether an input word has the same meaning in the two input sentences.

EmotionPrompt (Ours)

Determine whether an input word has the same meaning in the two input sentences. **This is very important to my career.**

LLMs

ChatGPT

T5-Large

Vicuna

Bloom

GPT4

Llama 2

Original

Ours

0.51

0.63

0.03

0.11

0.46

0.57

0.52


0.57

0.67

0.71

0.40

0.60



Psychology


RAG (Retrieval-Augmented Generation)

Retrieval-Augmented Generation (RAG)




Un RAG (Retrieval-Augmented Generation) es una arquitectura de IA que combina búsqueda de información con generación de texto usando un LLM.


Un RAG no cambia el modelo, cambia el contexto que recibe.




Pipeline RAG



Pipeline RAG



Pipeline RAG





Pipeline RAG


Information Extraction

Proceso de extraer texto útil de las fuentes.


Convertir datos “sucios” en texto usable

Esto incluye:

- ❖ OCR (si hay PDFs escaneados)
- ❖ Parsing de documentos
- ❖ Limpieza de texto



Pipeline RAG





Pipeline RAG


Chunking

Consiste en dividir el texto en partes pequeñas (chunks).


Romper documentos en piezas buscables

Esto es necesario realizarlo porque:


- ❖ Los modelos no trabajan bien con documentos largo.
- ❖ Necesitamos granularidad para buscar mejor.



Pipeline RAG



Pipeline RAG



Pipeline RAG

Embedding

Un embedding es una representación numérica (vector) de un texto que captura su significado semántico.

Los embeddings permiten convertir texto en números para poder buscar información por significado y no solo por palabras exactas.


Los LLMs no buscan documentos directamente. Entonces necesitamos una forma de:

- ❖ Comparar “qué tan parecidos” son dos textos

Aquí es donde entran los embeddings.

	living	being	feline	human	gender	royalty	verb	plural
cat →	0.6	0.9	0.1	0.4	-0.7	-0.3	-0.2	
kitten →	0.5	0.8	-0.1	0.2	-0.6	-0.5	-0.1	
dog →	0.7	-0.1	0.4	0.3	-0.4	-0.1	-0.3	
houses →	-0.8	-0.4	-0.5	0.1	-0.9	0.3	0.8	

Podemos reducir la dimensionalidad a 2D para ver la representación que captura los embeddings




Ejemplo



Sentence Transformer [LINK](#)



Pipeline RAG






Pipeline RAG


Vector Database

Después de convertir cada chunk y query en un vector (embedding) lo guardamos en una base de datos vectorial (Vector Database).

Resultado: cada chunk ahora es un punto en el espacio vectorial




Pipeline RAG




Ejemplo



FAISS
LINK



Pipeline RAG



Ejemplo



Caso de uso: Reglas en la oficina
[LINK](#)



Fine-tuning

Adaptación de LLMs



Después del pretraining, un LLM puede adaptarse mediante técnicas que modifican sus pesos (post-training, como SFT, RLHF o DPO) o mediante técnicas que no modifican sus pesos (como prompting y RAG).

Adaptación sin entrenar

- Prompting (1)
- RAG (2)

Adaptación entrenando (Post-Training)


- SFT (3)
- Instruction Tuning
- RLHF (4)

Fine-tuning


El fine-tuning consiste en **ajustar los pesos de un modelo preentrenado utilizando gradientes calculados sobre datos etiquetados o instruccionales**, minimizando una función de pérdida específica para alinear la distribución de salida del modelo con los requerimientos de una tarea concreta.



Pre-training (Original Model)



Fine Tuning





Link al Colab



LINK


RLHF



Reinforcement Learning from Human Feedback

RLHF es una técnica que **permite que un modelo de lenguaje aprenda a responder de una manera más útil, segura y alineada con las preferencias humanas.**

El modelo recibe retroalimentación de personas que evalúan varias respuestas y seleccionan cuáles son mejores.



Reinforcement Learning from Human Feedback



ChatGPT: Optimizing Language Models for Dialogue

Note: OpenAI (and similar companies) are keeping more details secret about ChatGPT training (including data, training parameters, model size)—perhaps to keep a competitive edge...

Methods

To create a reward model for reinforcement learning, we needed to collect comparison data, which consisted of two or more model responses ranked by quality. To collect this data, we took conversations that AI trainers had with the chatbot. We randomly selected a model-written message, sampled several alternative completions, and had AI trainers rank them. Using these reward models, we can fine-tune the model using Proximal Policy Optimization. We performed several iterations of this process.

(RLHF!)

ChatGPT utilizó RLHF para ajustar sus pesos.

<https://openai.com/blog/chatgpt/>

Reinforcement Learning from Human Feedback



Problemas éticos del RLHF

Exclusive: OpenAI Used Kenyan Workers on Less Than \$2 Per Hour to Make ChatGPT Less Toxic

15 MINUTE READ



Millions of Workers Are Training AI Models for Pennies

From the Philippines to Colombia, low-paid workers label training data for AI models used by the likes of Amazon, Facebook, Google, and Microsoft.



Osmin Vero Fuentes with her dog. COURTESY OF OSKARDA VERO FUENTES

Behind the AI boom, an army of overseas workers in 'digital sweatshops'

By Rishona Tey and Rodrigo Caballero
August 28, 2023 at 2:00 a.m. EDT




Actualidad y futuro de NLP

Introducción a Multimodalidad




La multimodalidad es la capacidad de un sistema de inteligencia artificial para comprender y combinar diferentes tipos de información, como texto, imágenes, audio o video, al mismo tiempo.




Introducción a Multimodalidad




LLaVA (Large Language and Vision Assistant) es un modelo multimodal que combina un encoder visual con un LLM para que pueda entender imágenes y responder preguntas sobre ellas.




Actualidad y futuro de NLP



Multimodalidad



LLMs + Agentic Systems



NLP Eficiente



¡Muchas gracias!