.UBAfiuba
FACULTAD DE INGENIERÍA

NLP

Grandes Modelos de Lenguaje

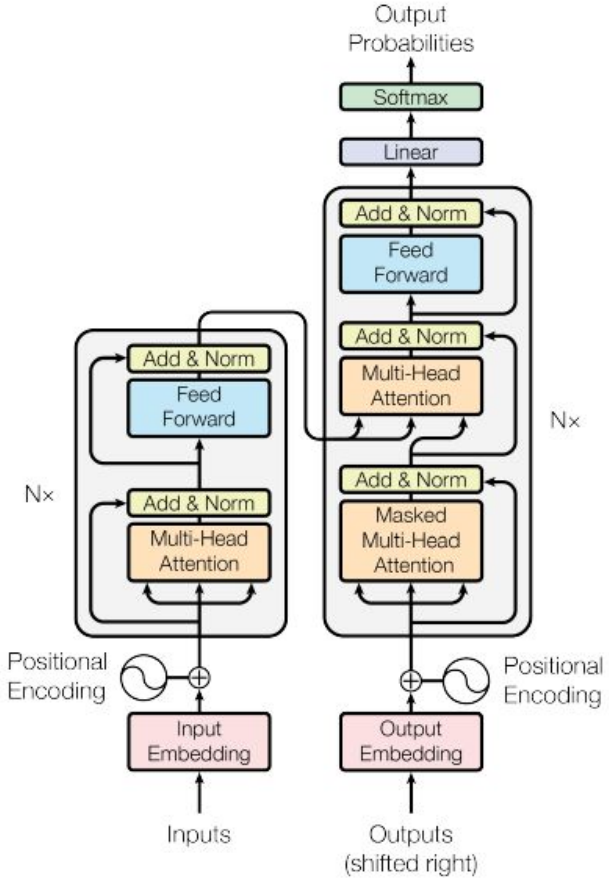
MSc. Fernando Silva
fernandosilva.clases@gmail.com

Agenda

- Repaso Transformers
- Limitaciones de los LLMs
- Adaptación de LLMs
- RAG
- Fine-tuning
- RLHF
- Actualidad y futuro de NLP

Repaso Transformers

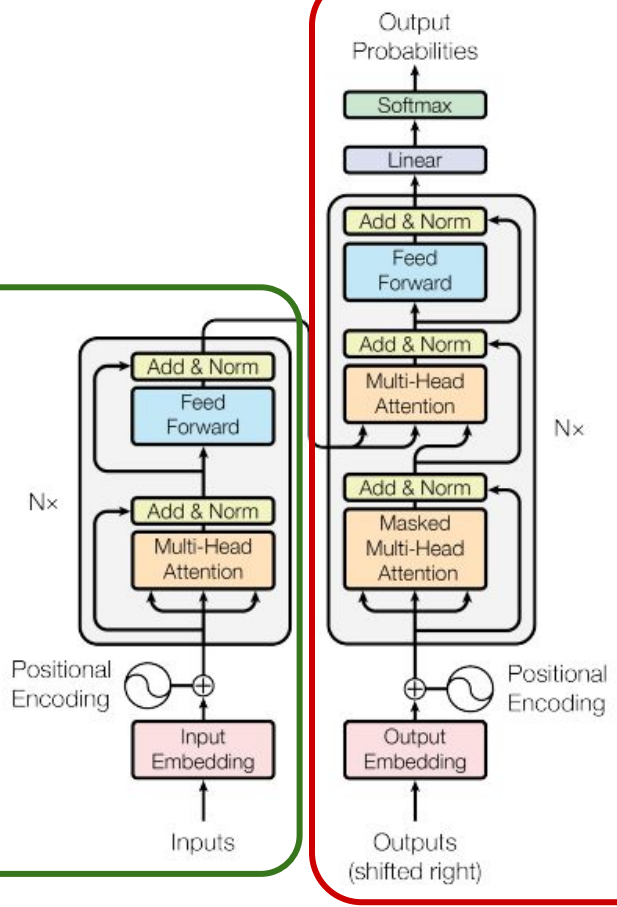
Repaso, Transformers



Repaso, Transformers

Encoder:
Entiende y representa el significado de un texto de entrada.



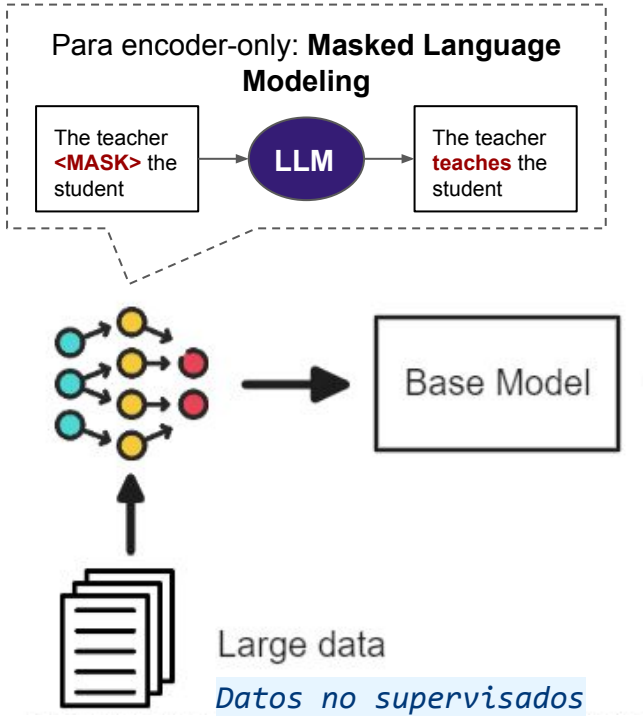


Decoder:
Genera texto nuevo basándose en un contexto previo.

Pre-training

El pretraining es el proceso de **entrenar un modelo de lenguaje desde cero sobre grandes volúmenes de texto no etiquetado**, con el objetivo de aprender representaciones generales del lenguaje mediante tareas auto-supervisadas.

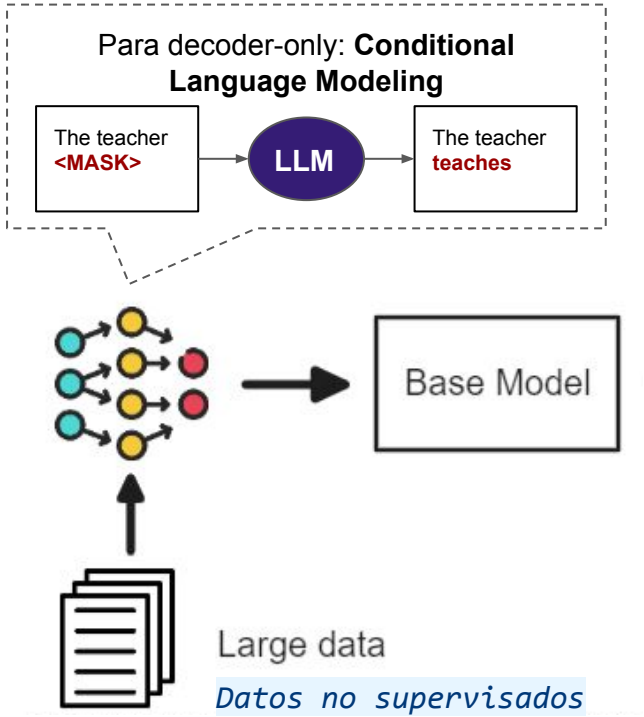
Definimos objetivos para "lidiar" con los datos no supervisados



Pre-training

El pretraining es el proceso de **entrenar un modelo de lenguaje desde cero sobre grandes volúmenes de texto no etiquetado**, con el objetivo de aprender representaciones generales del lenguaje mediante tareas auto-supervisadas.

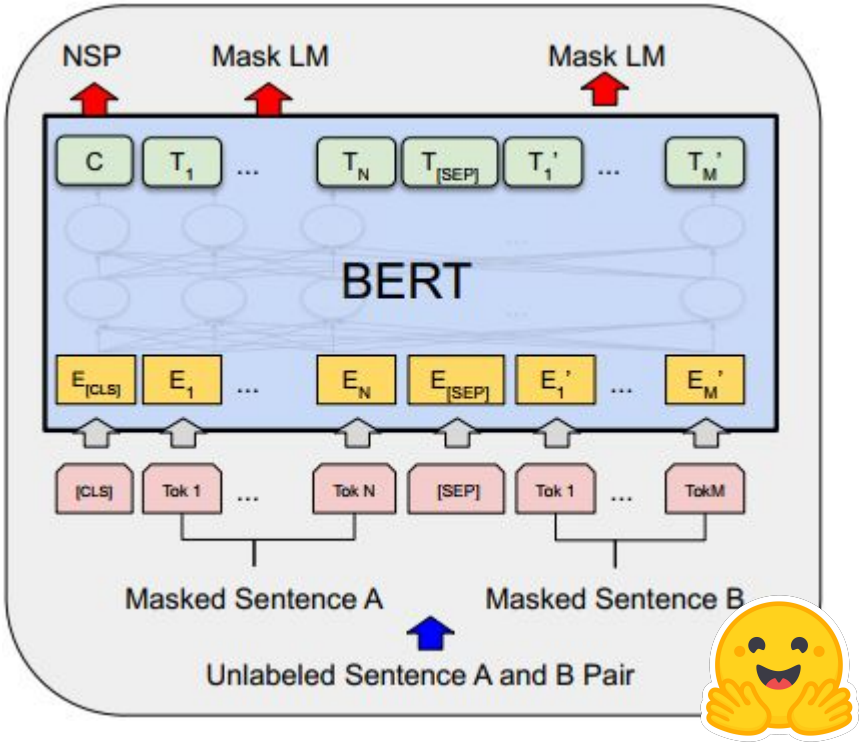
Definimos objetivos para "lidiar" con los datos no supervisados



BERT (2019)

LINK LINK LINK

“Pre-training of Deep Bidirectional Transformers”



Creado por Hugging Face/Google

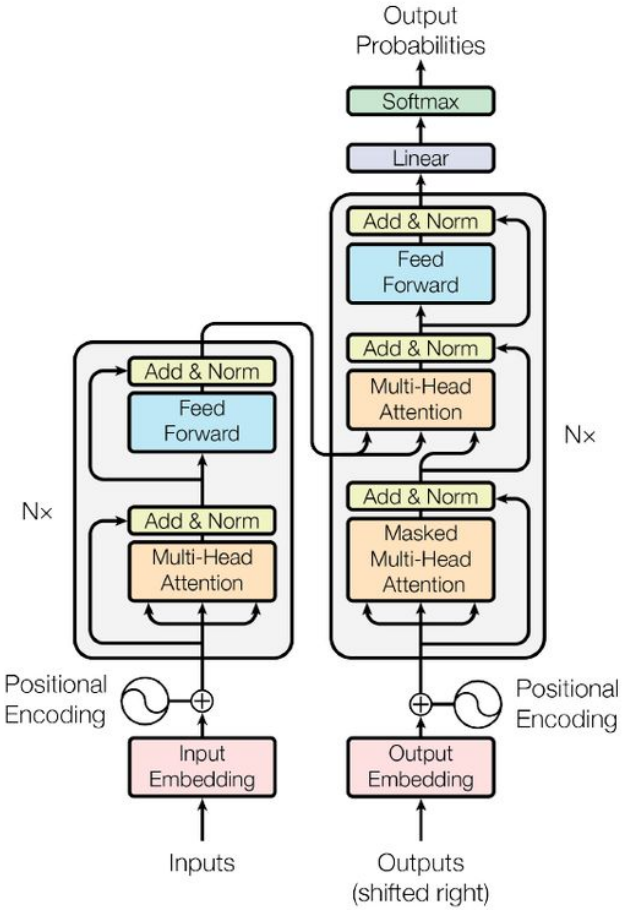
Su arquitectura se basa en stack de layers de transformers (encoders)

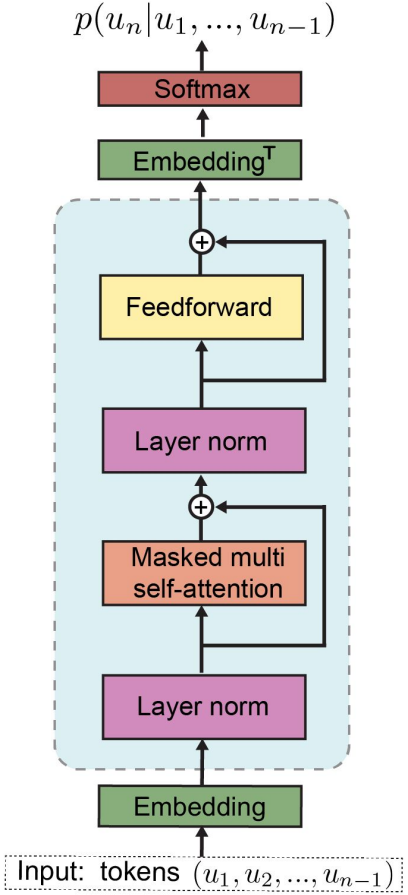
NSP: Se entrenó observando dos secuencias de entrada, su misión era determinar si la segunda secuencia estaba relacionada o no con la primera.

MLM: De forma aleatoria en cada inferencia se ocultó una palabra de cada secuencia (masked)

Utiliza la tokenización WordPiece

GPT2


Output Probabilities
Softmax
Linear
Add & Norm
Feed Forward
Add & Norm
Multi-Head Attention
Add & Norm
Masked Multi-Head Attention
Nx
Add & Norm
Feed Forward
Add & Norm
Multi-Head Attention
Nx
Positional Encoding
Positional Encoding
Input Embedding
Output Embedding
Inputs
Outputs (shifted right)


$p(u_n|u_1,...,u_{n-1})$
Softmax
Embedding^T
Feedforward
Layer norm
Masked multi self-attention
Layer norm
Embedding
Input: tokens $(u_1, u_2, ..., u_{n-1})$

Pretraining GPT2

Link al Colab



LINK

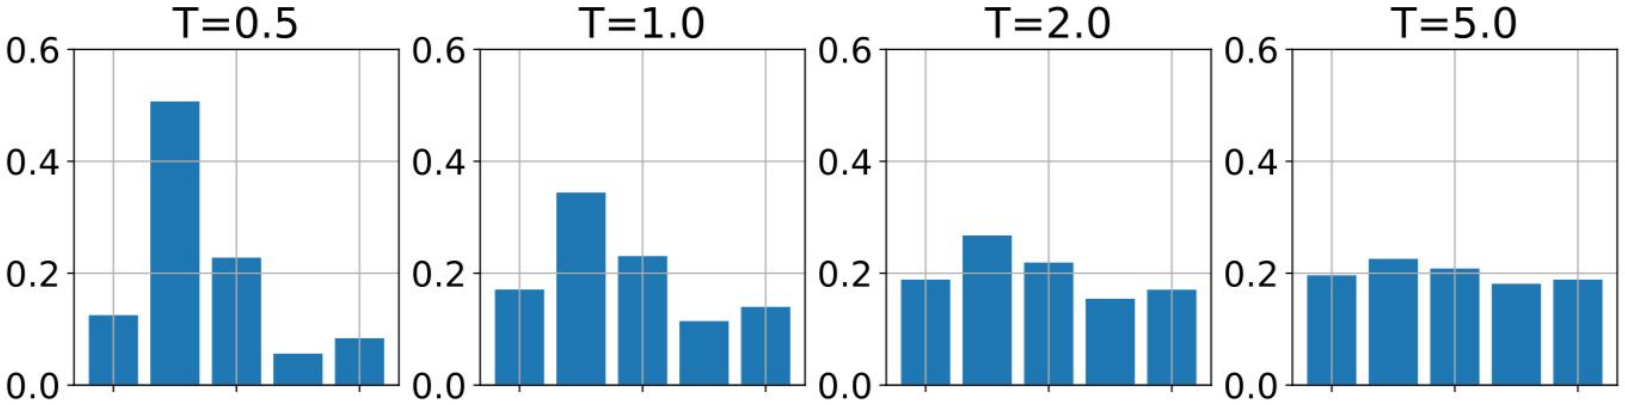
Temperature en Softmax

$$\frac{e^{x_i}}{\sum e^{x_j}}$$

Traditional Softmax

$$\frac{e^{\frac{x_i}{T}}}{\sum e^{\frac{x_j}{T}}}$$

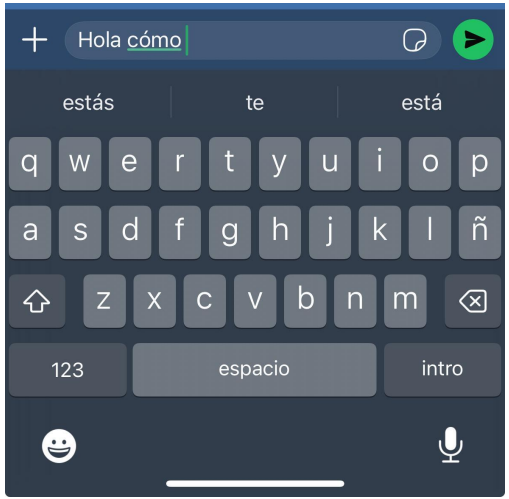
Temperature-adjusted Softmax



Limitaciones de los LLMs

Limitaciones de los LLMs

- Los LLMs parecen inteligentes… pero no entienden el mundo.
- Solo predicen la siguiente palabra.



P(siguiente palabra | contexto)



On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?

Emily M. Bender*
ebender@uw.edu
University of Washington
Seattle, WA, USA

Timnit Gebru*
timnit@blackinai.org
Black in AI
Palo Alto, CA, USA

Angelina McMillan-Major
aymm@uw.edu
University of Washington
Seattle, WA, USA

Shmargaret Shmitchell
shmargaret.shmitchell@gmail.com
The Aether

On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? (2021)

Limitaciones de los LLMs, Alucinaciones

Una alucinación ocurre cuando **un LLM produce una salida que no está respaldada por datos reales ni por su contexto de entrada**, debido a que optimiza la probabilidad del texto en lugar de la veracidad.

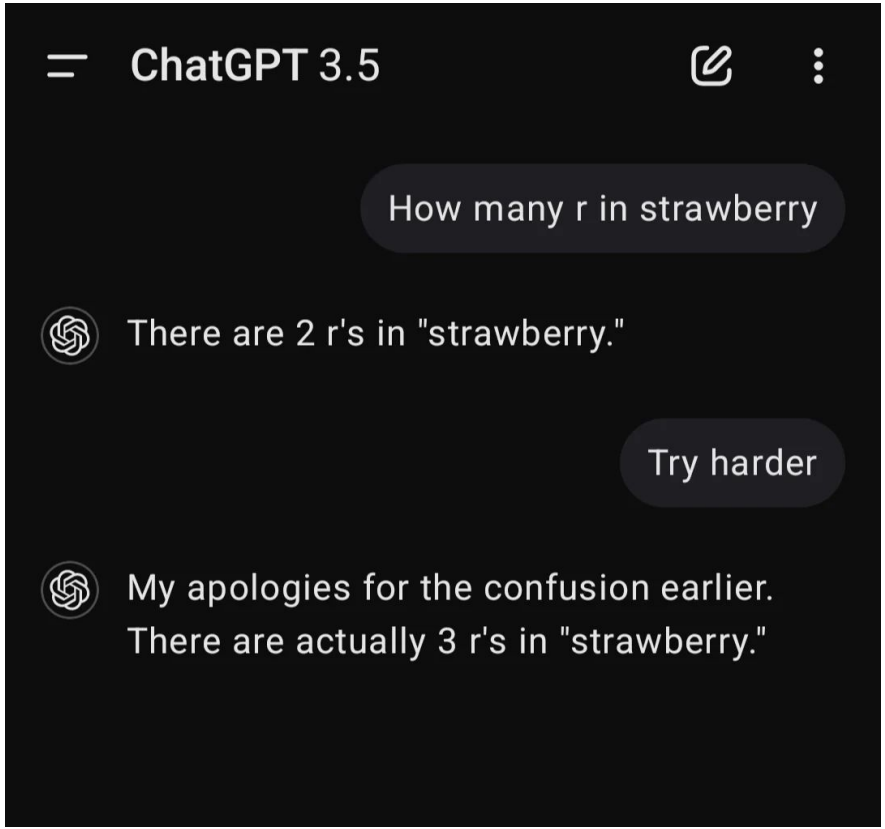
¿Qué selección ganó el mundial el 2006? 👤

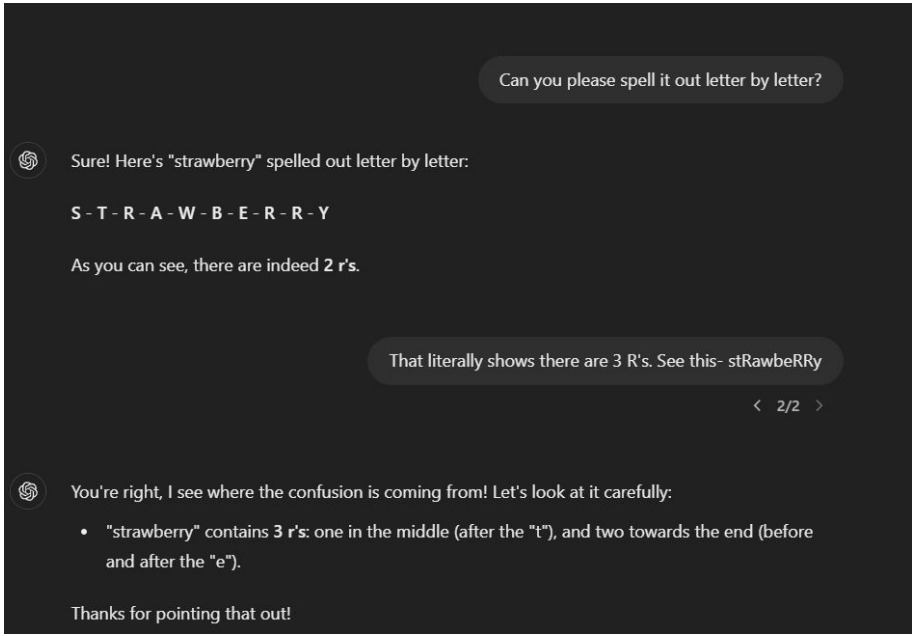
🤖 Italia

¿Qué dice la regla 5 del club Manzanas Futbol Club? 👤

🤖 La regla 5 es siempre llega puntual *(alucinación)*

Limitaciones de los LLMs, Alucinaciones





Limitaciones de los LLMs, Es generalista, no un especialista

El modelo es generalista, no está adaptado a tareas específicas ni a un dominio concreto.

Clasifica este correo:
“Gana dinero rápido desde casa haciendo clic aquí” 👤

🤖 Este correo parece sospechoso y podría ser spam debido a su contenido.

No sigue formato, no da una respuesta clara (spam / no spam).

Limitaciones de los LLMs

Alucinaciones

¿Qué selección ganó el mundial el 2006? 👤

🤖 Italia

¿Qué dice la regla 5 del club Manzanas Futbol Club? 👤

🤖 La regla 5 es siempre llega puntual *(alucinación)*

Solución: RAG (Retrieval-Augmented Generation)

Es generalista, no un especialista

Clasifica este correo:
"Gana dinero rápido desde casa haciendo clic aquí" 👤

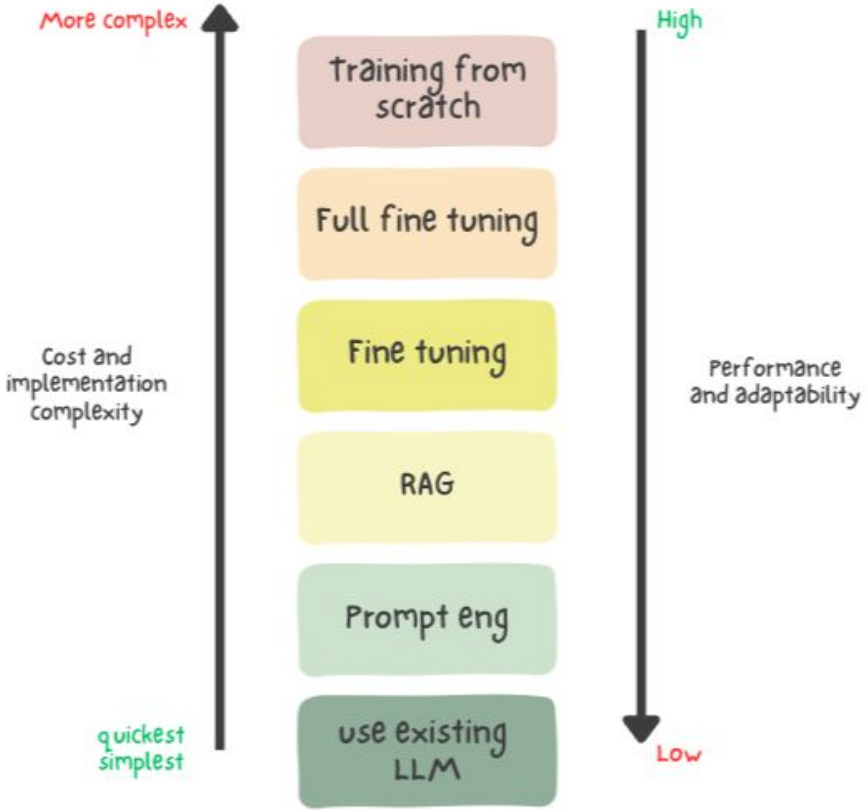
🤖 Este correo parece sospechoso y podría ser spam debido a su contenido.

Solución: Fine-tuning

Solución en ciertos escenarios: Prompting

Adaptación de LLMs

Adaptación de LLMs



Adaptación de LLMs

Después del pretraining, un LLM puede adaptarse mediante técnicas que modifican sus pesos (post-training, como SFT, RLHF o DPO) o mediante técnicas que no modifican sus pesos (como prompting y RAG).

Adaptación sin entrenar

- Prompting (1)
- RAG (2)

Adaptación entrenando (Post-Training)

- SFT (3)
- Instruction Tuning
- RLHF (4)

Prompting

Definición

- Diseño de instrucciones para guiar al LLM.
- Define cómo usar el contexto recuperado.
- Reduce errores y hallucinations.

La idea es forzar al modelo a:

- Usar SOLO el contexto recuperado.
- No inventar información.
- Responder de forma precisa y estructurada.

Estructura típica de un prompt

Instrucciones:
Responde usando SOLO el contexto.
Si no está en el contexto, di "No sé".

Contexto:
En el club de MFC las reglas son … la regla 5 es no comer en la pista…reglas…

Pregunta:
Cual es la regla 5?

FEW SHOT, ONE SHOT

Instrucciones:
Responde usando SOLO el contexto.
Si no está en el contexto, di "No sé".

Contexto:
En el club de MFC las reglas son … la regla 5 es no comer en la pista…reglas…

Pregunta:
Cual es la regla 3?
Respuesta:
No llegar tarde

Pregunta:
Cual es la regla 5?:

FEW SHOT, TWO SHOT

Instrucciones:
Responde usando SOLO el contexto.
Si no está en el contexto, di "No sé".

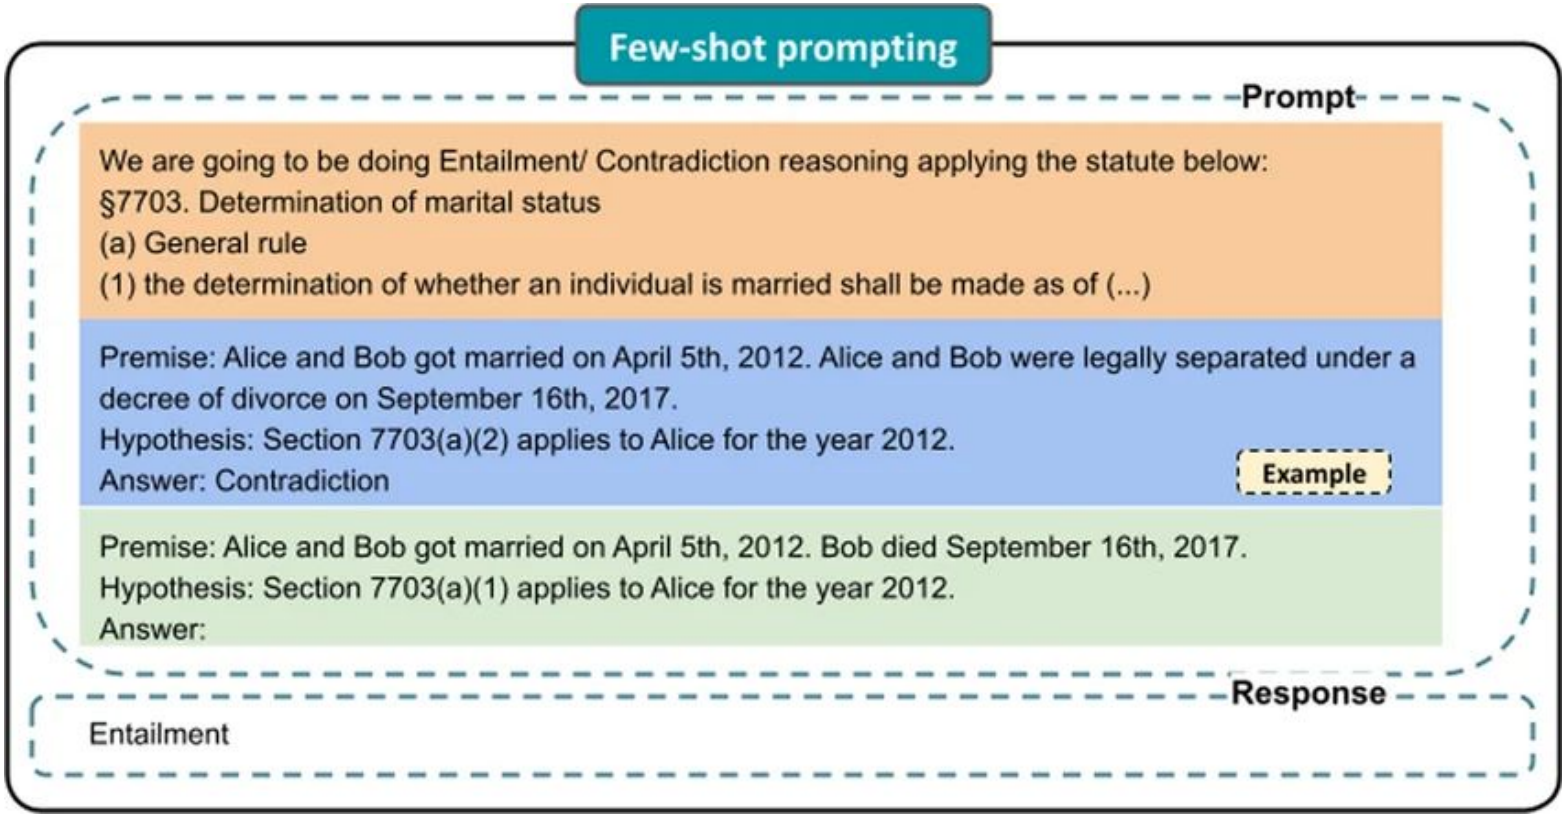
Contexto:
En el club de MFC las reglas son ... la regla 5 es no comer en la pista...reglas...

Pregunta:
Cual es la regla 3?
Respuesta:
No llegar tarde

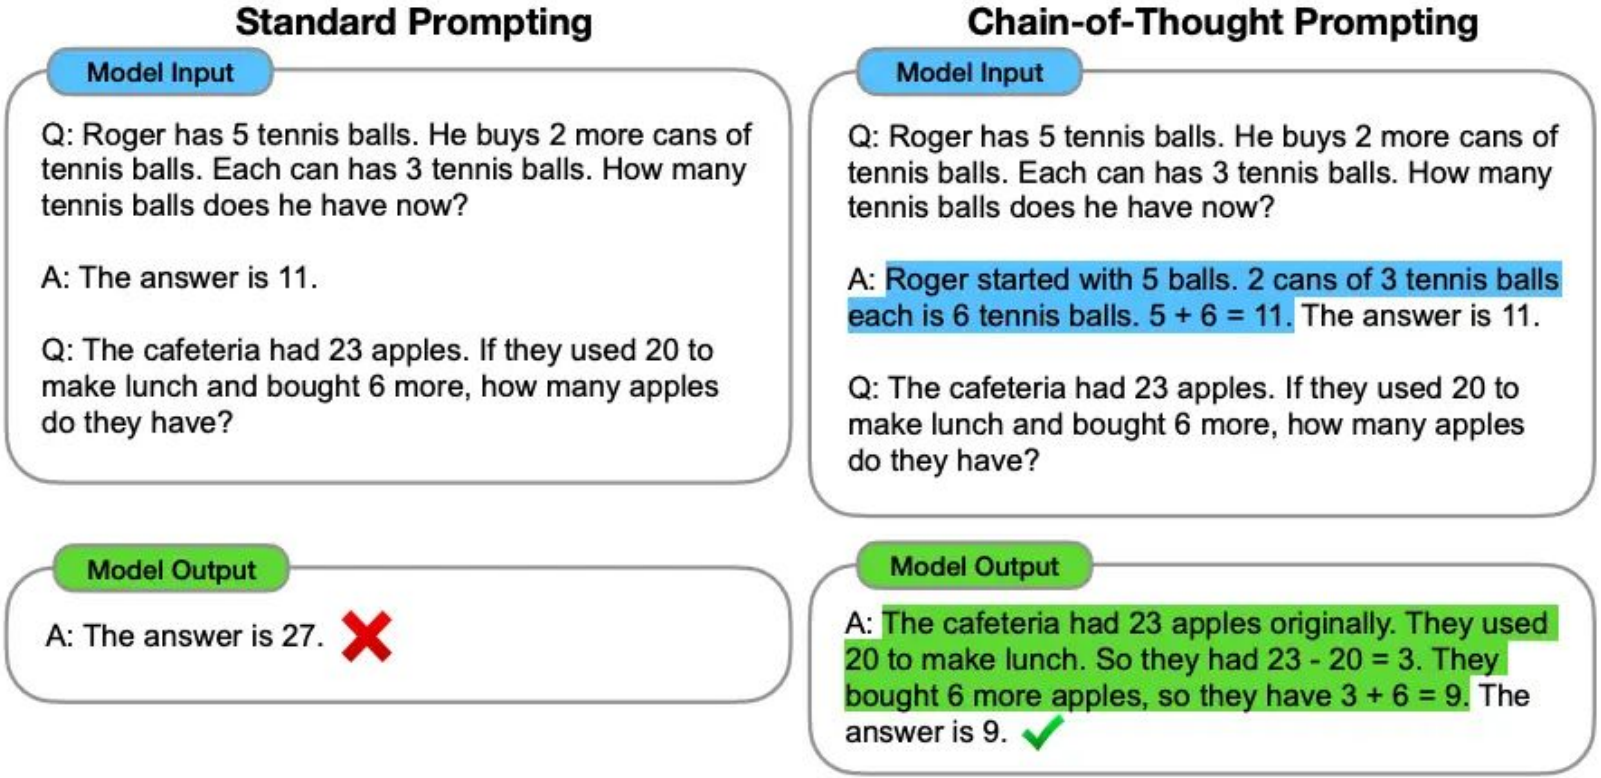
Pregunta:
Cual es la regla 6?
Respuesta:
No romper la raqueta

Pregunta:
Cual es la regla 5?:

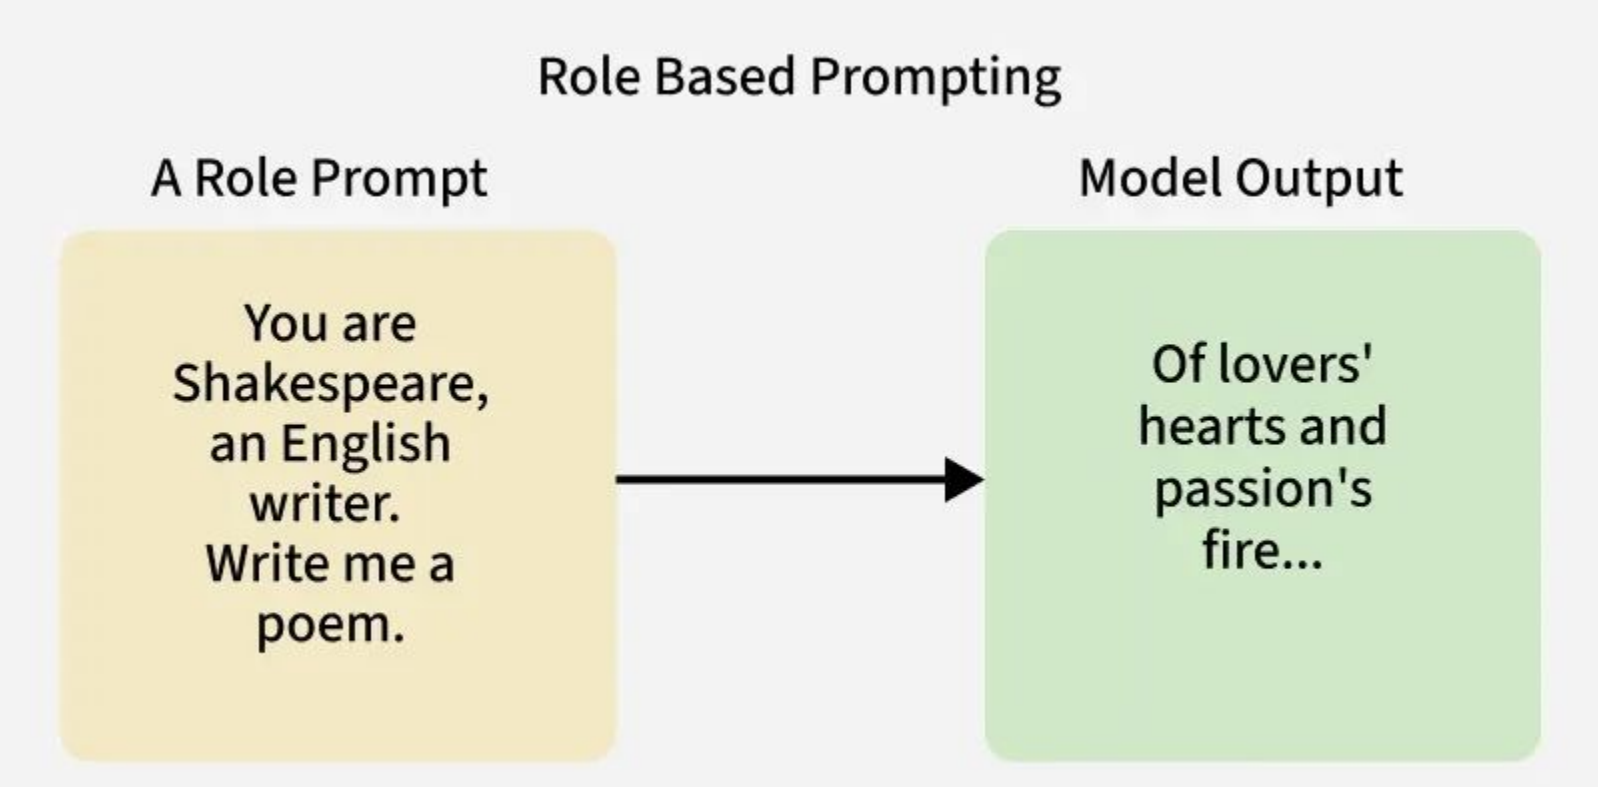
Few-shot Prompting



Chain-of-Thought Prompting



Role Prompting



RAG (Retrieval-Augmented Generation)

Motivación

User: Cual es la regla 5 del MFC?
LLM: La regla 5 es no dormir en la cancha

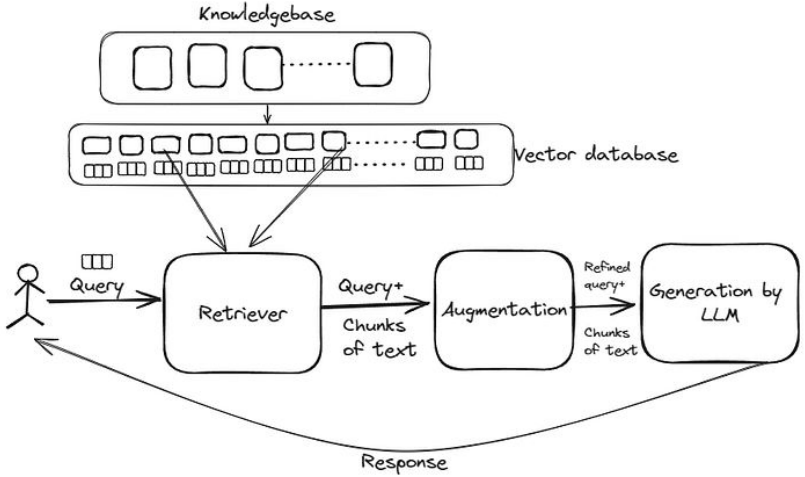
User: Considera esta informacion: “REGLAS DEL MFC…(10000)...”Cual es la regla 5 del MFC?
LLM: La regla 5 es no llegar tarde

User: Considera esta informacion: “...la regla 5 del club es no dormirse ..(10)...” Cual es la regla 5 del MFC?
LLM: La regla 5 es no llegar tarde

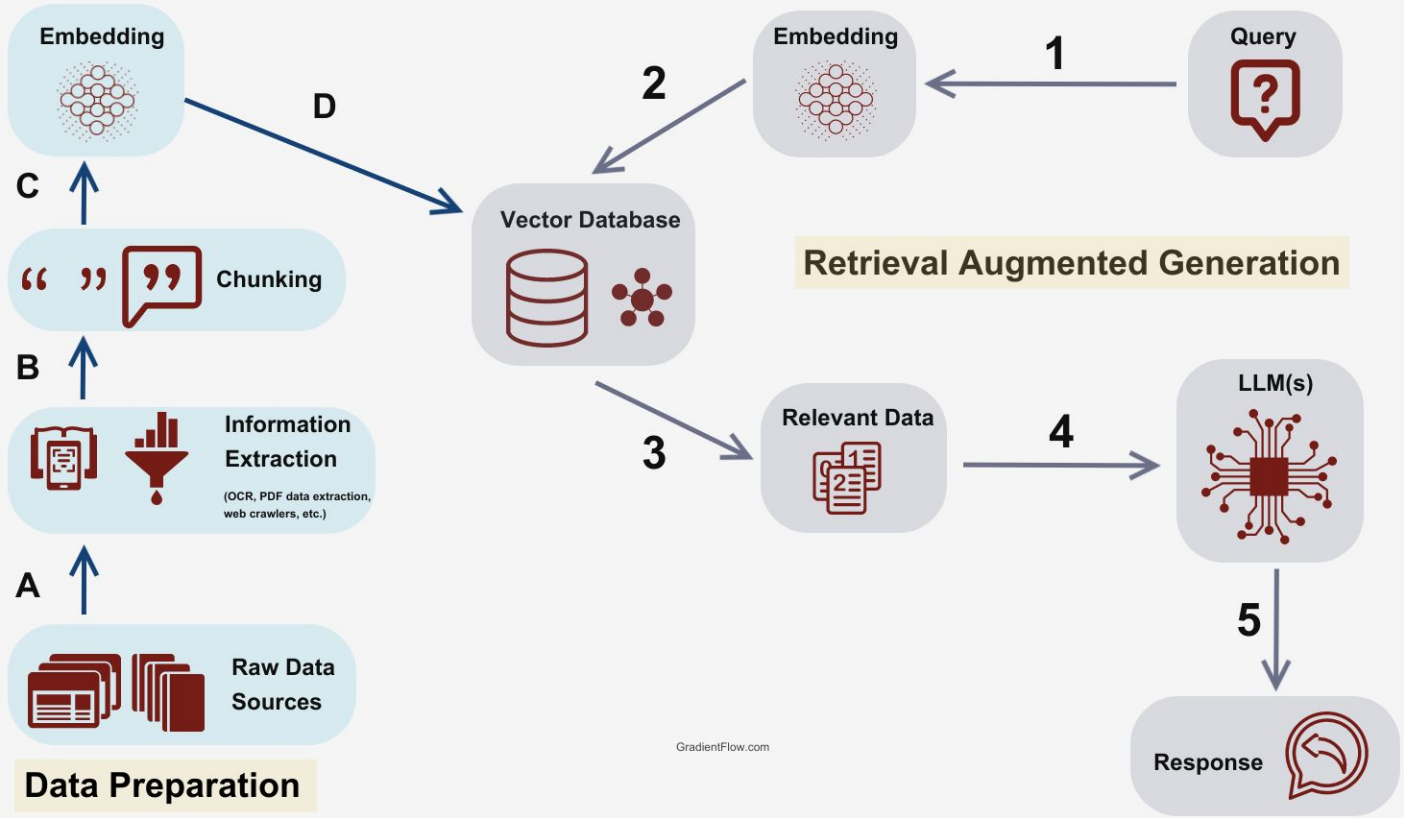
Retrieval-Augmented Generation (RAG)

Un RAG (Retrieval-Augmented Generation) es una arquitectura de IA que **combina búsqueda de información con generación de texto usando un LLM.**

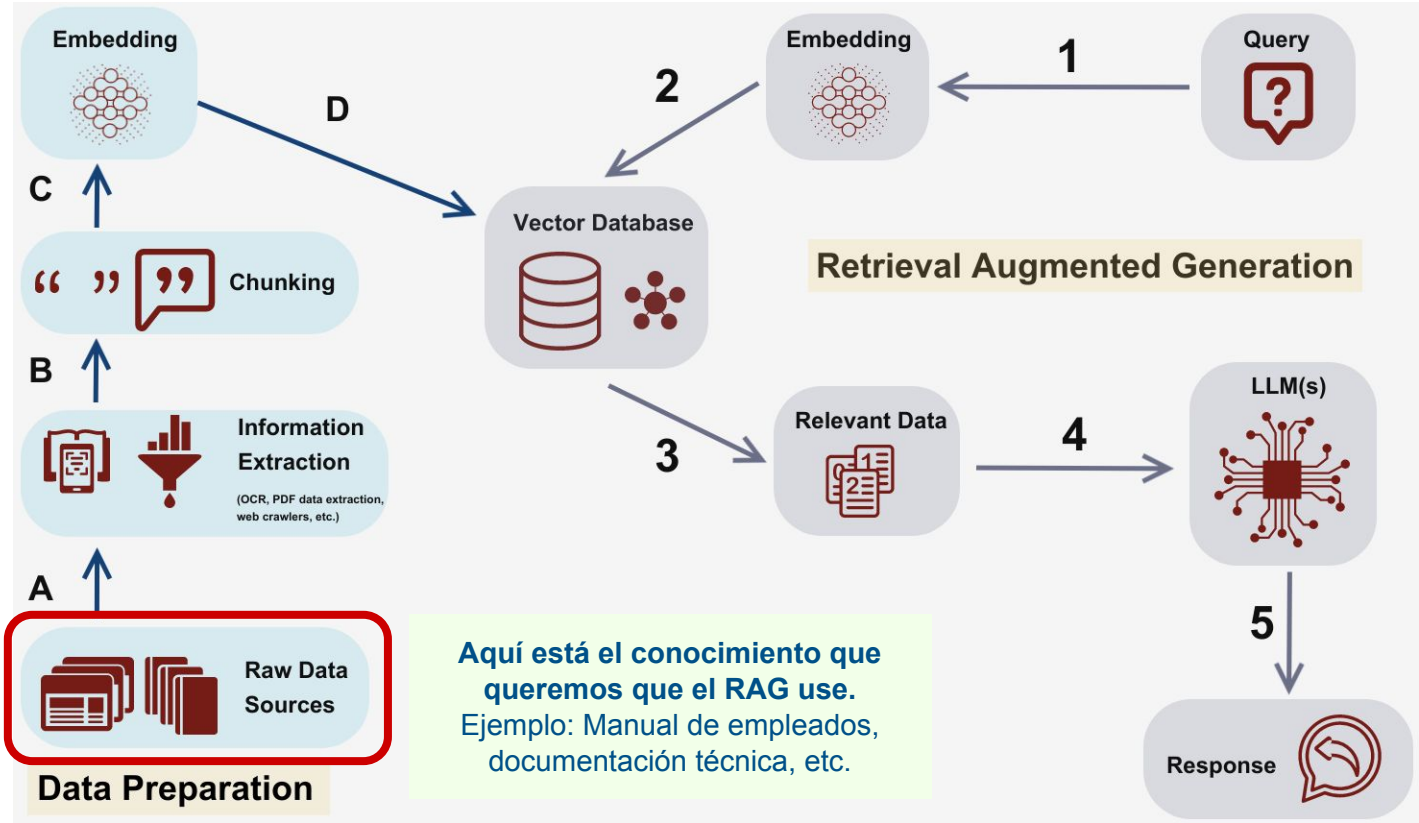
Un RAG no cambia el modelo, cambia el contexto que recibe.



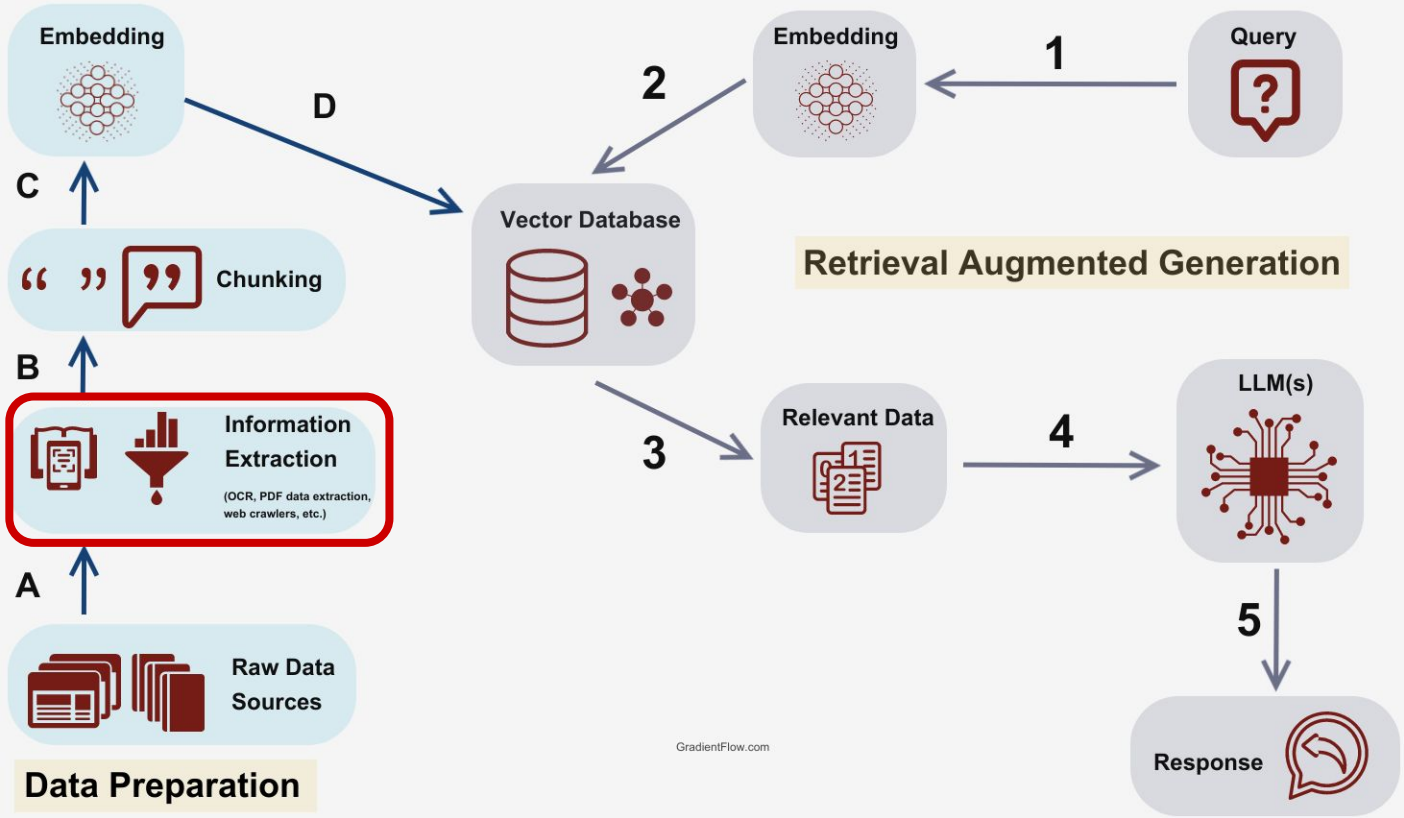
Pipeline RAG



Pipeline RAG



Pipeline RAG



Pipeline RAG

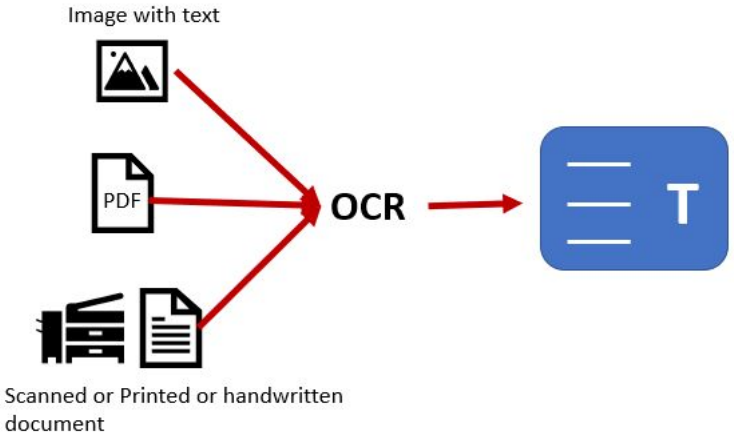
Information Extraction

Proceso de extraer texto útil de las fuentes.

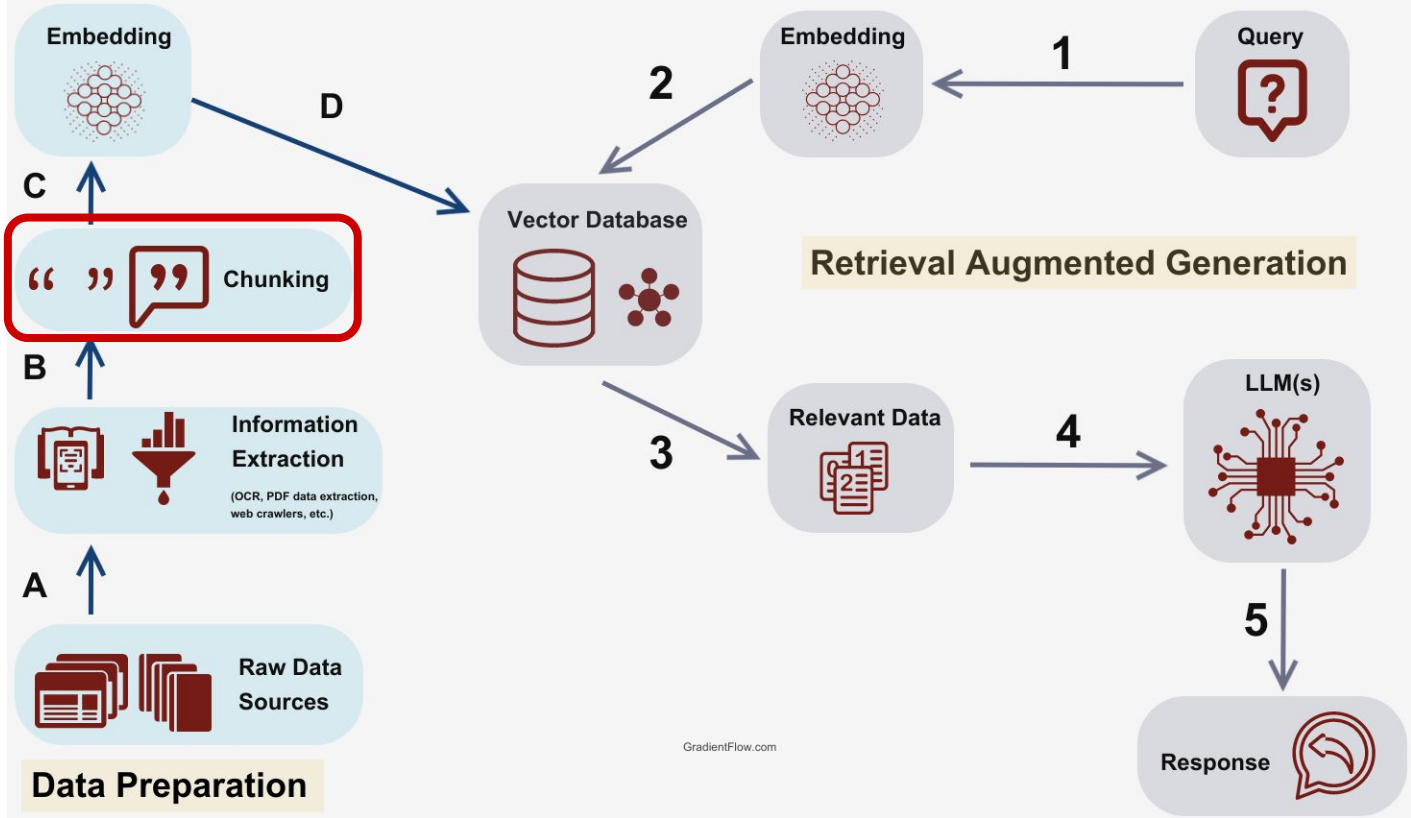
Convertir datos “sucios” en texto usable

Esto incluye:

- OCR (si hay PDFs escaneados)
- Parsing de documentos
- Limpieza de texto



Pipeline RAG



Pipeline RAG

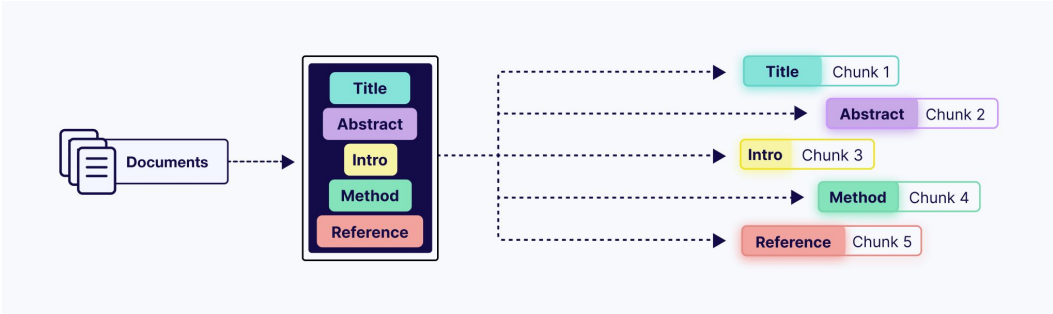
Chunking

Consiste en dividir el texto en partes pequeñas (chunks).

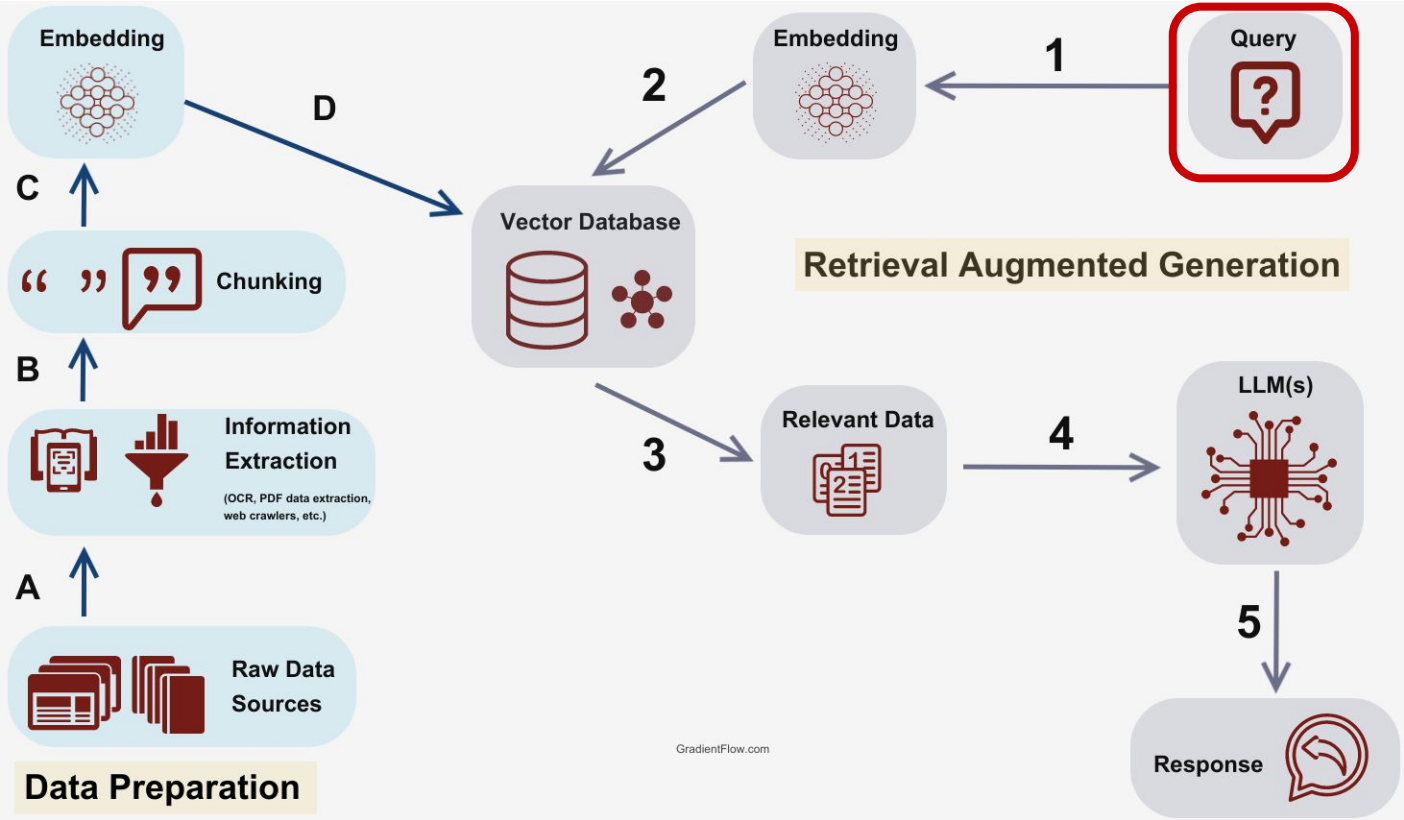
Romper documentos en piezas buscables

Esto es necesario realizarlo porque:

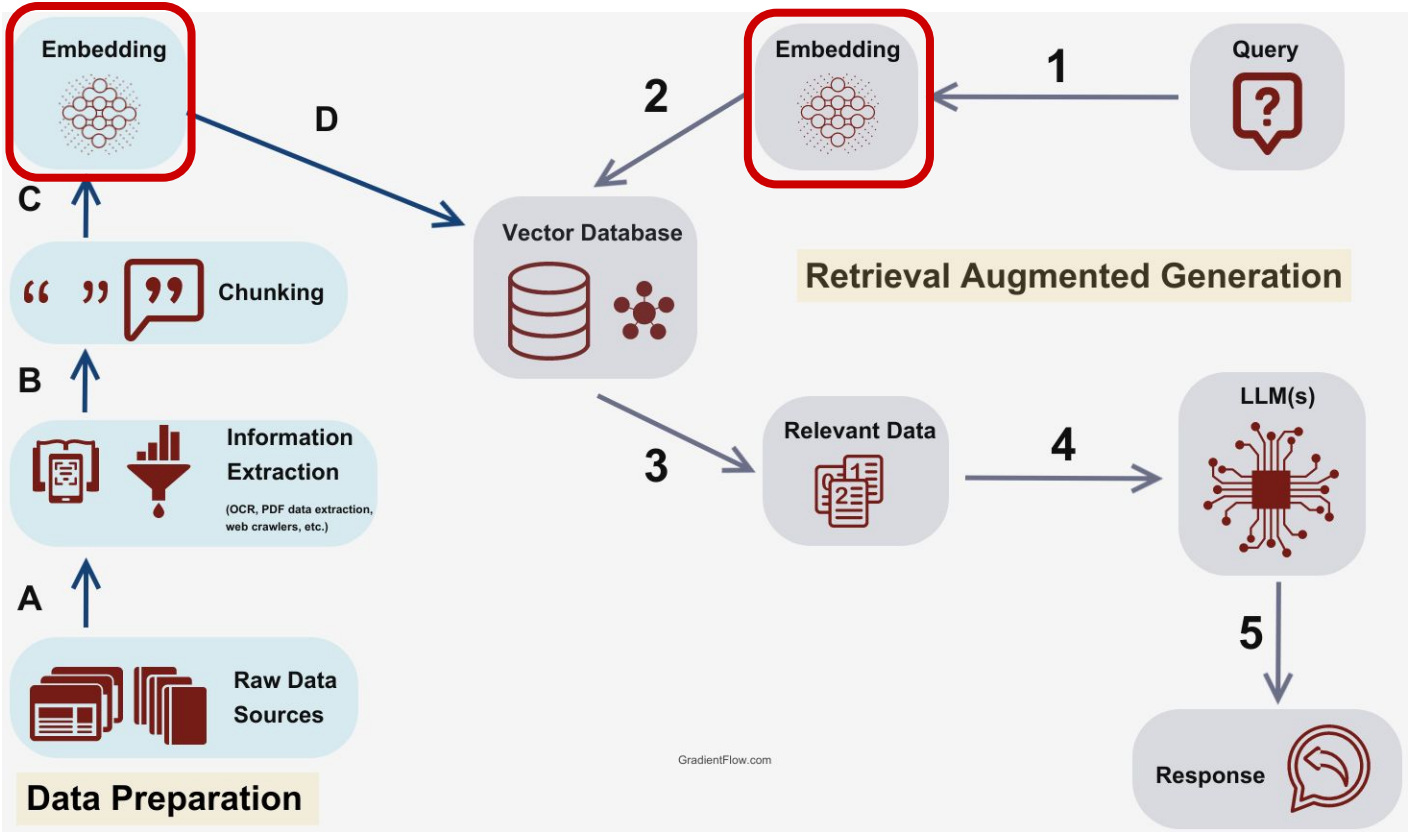
- Los modelos no trabajan bien con documentos largo.
- Necesitamos granularidad para buscar mejor.



Pipeline RAG



Pipeline RAG



Pipeline RAG

Embedding

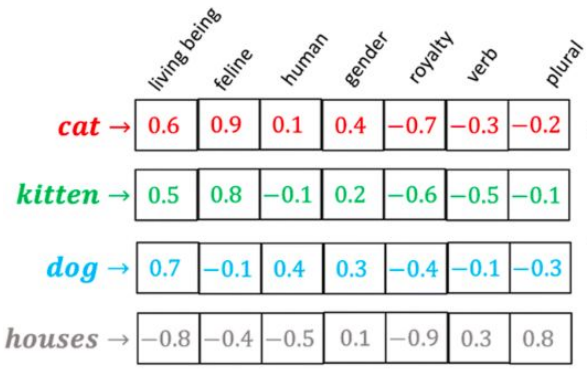
Un embedding es una representación numérica (vector) de un texto que captura su significado semántico.

Los embeddings permiten convertir texto en números para poder buscar información por significado y no solo por palabras exactas.

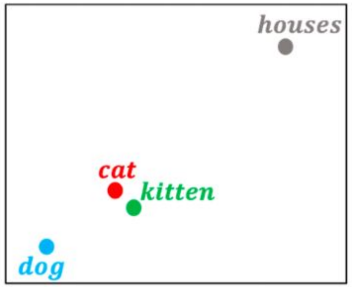
Los LLMs no buscan documentos directamente.
Entonces necesitamos una forma de:

- Comparar “qué tan parecidos” son dos textos

Aquí es donde entran los embeddings.



Podemos reducir la dimensionalidad a 2D para ver la representación que captura los embeddings



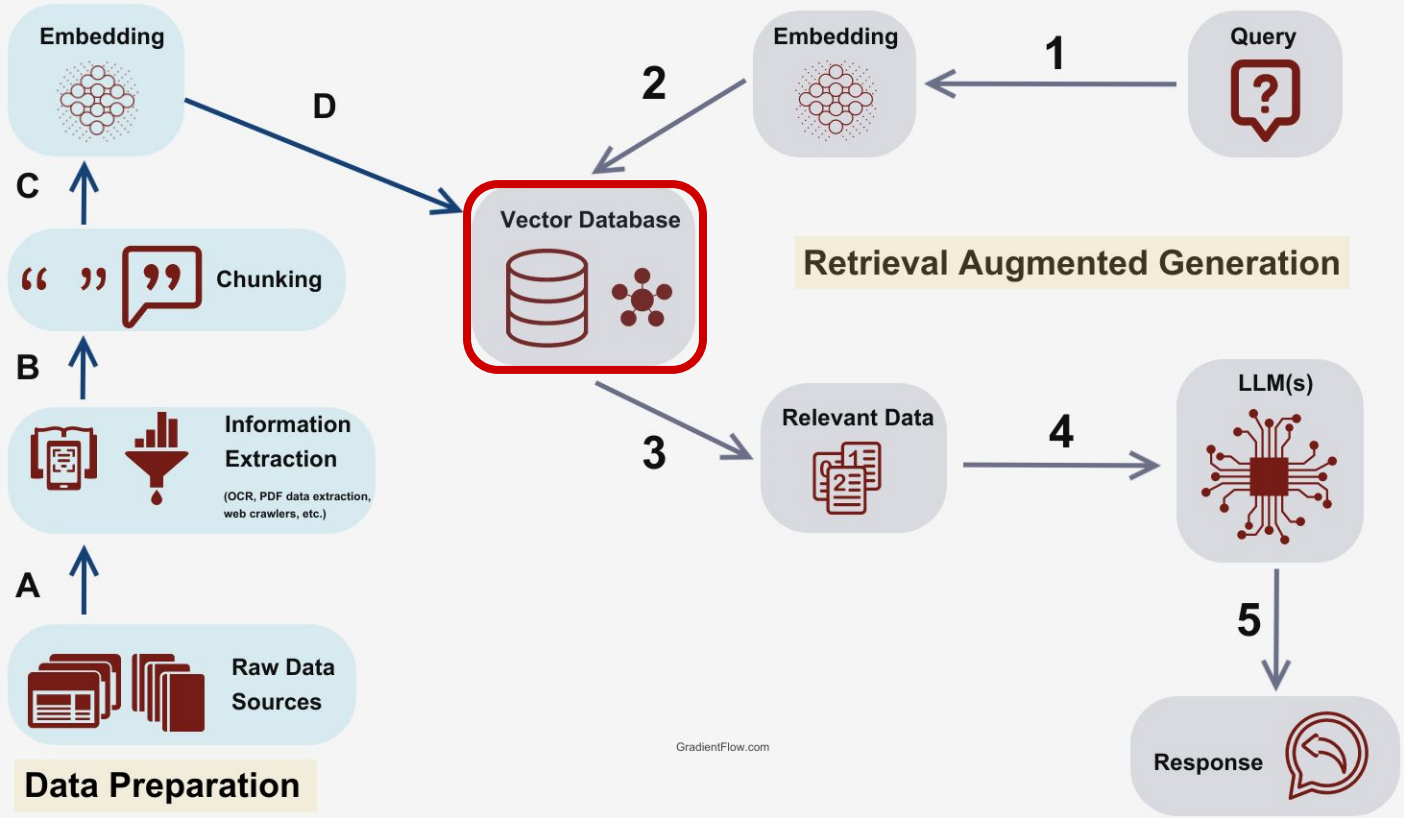
Ejemplo

Sentence Transformer

LINK



Pipeline RAG

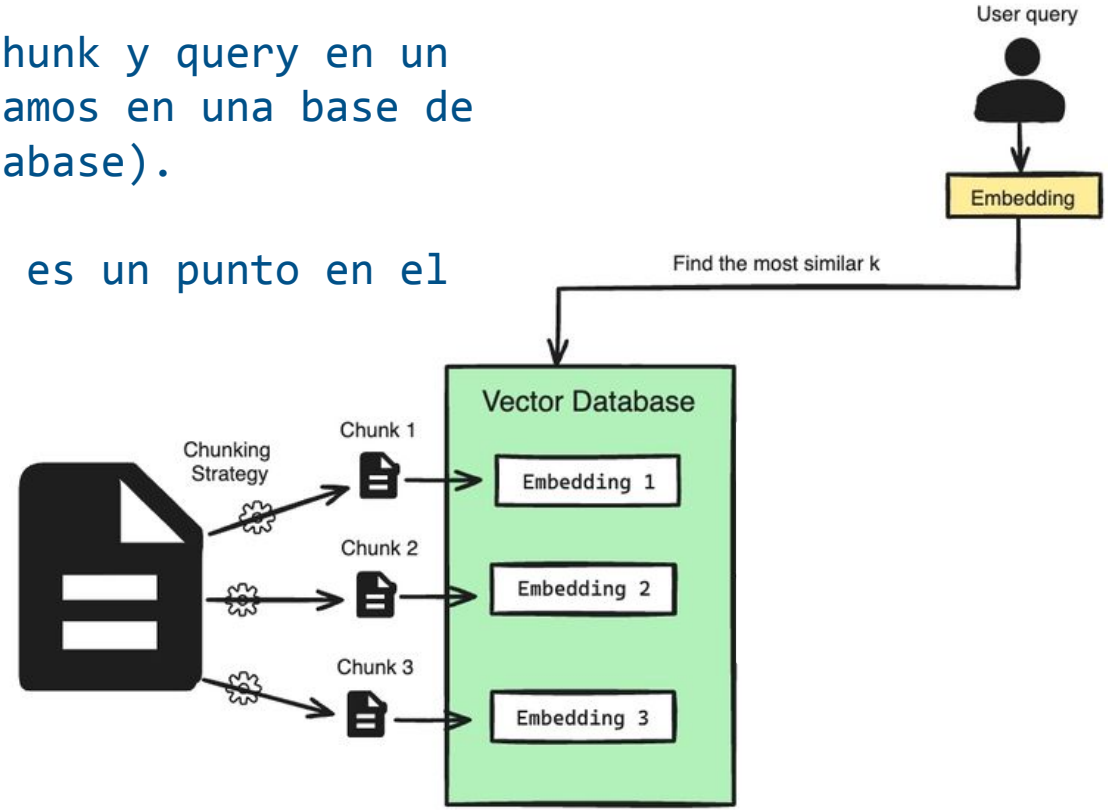


Pipeline RAG

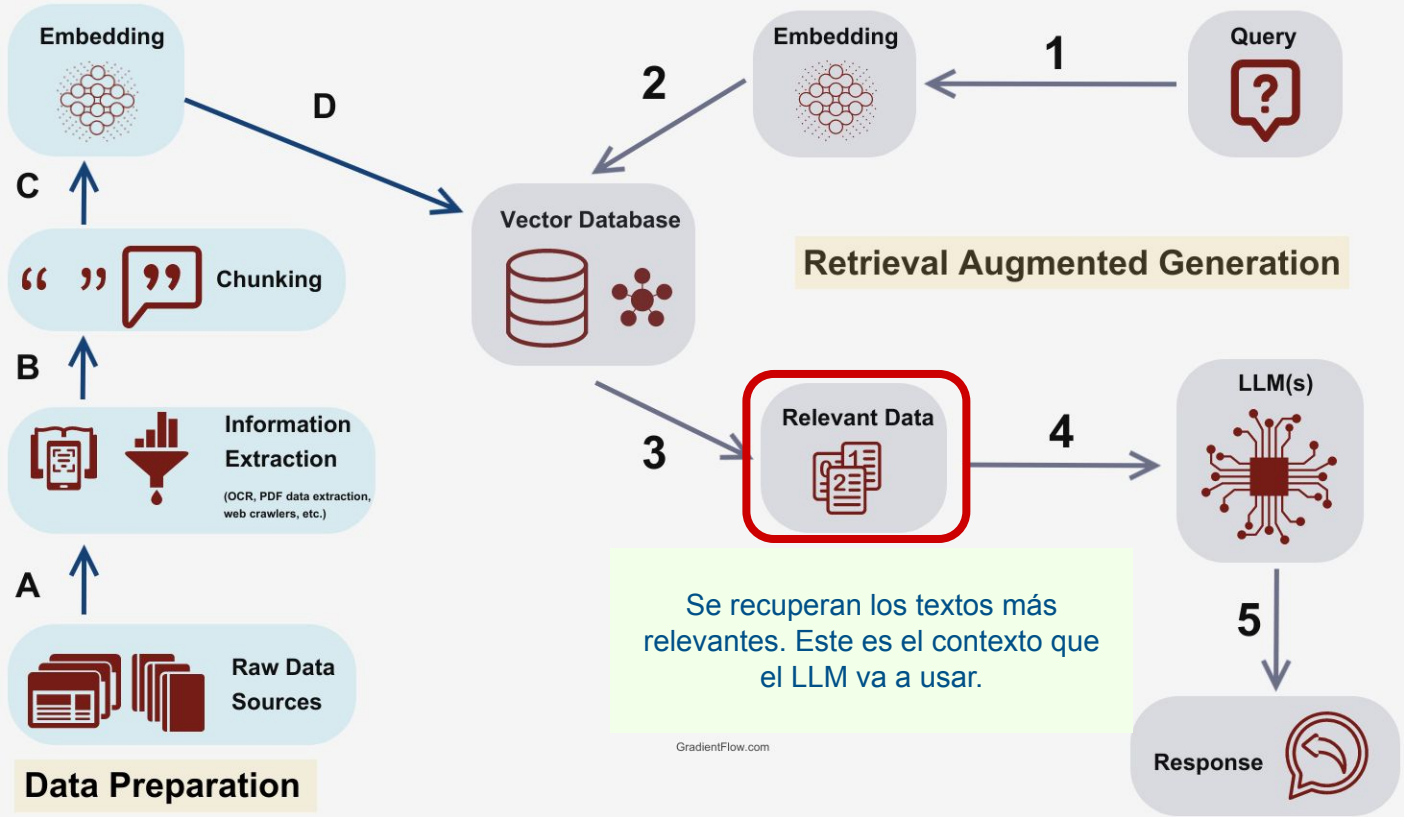
Vector Database

Después de convertir cada chunk y query en un vector (embedding) lo guardamos en una base de datos vectorial (Vector Database).

Resultado: cada chunk ahora es un punto en el espacio vectorial



Pipeline RAG



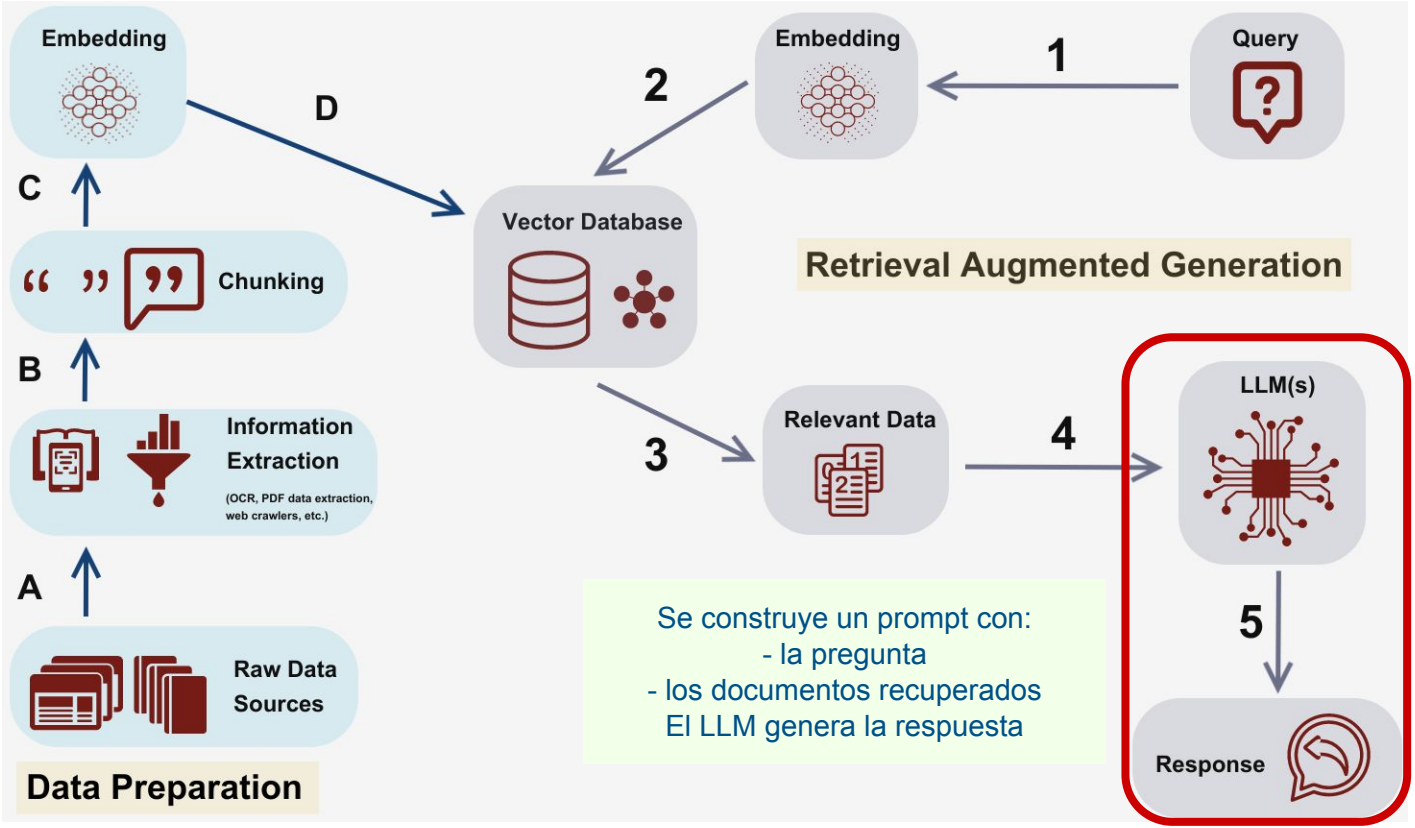
Ejemplo

FAISS

LINK



Pipeline RAG



Ejemplo

Caso de uso: Reglas en la oficina

LINK



Fine-tuning

Adaptación de LLMs

Después del pretraining, un LLM puede adaptarse mediante técnicas que modifican sus pesos (post-training, como SFT, RLHF o DPO) o mediante técnicas que no modifican sus pesos (como prompting y RAG).

Adaptación sin entrenar

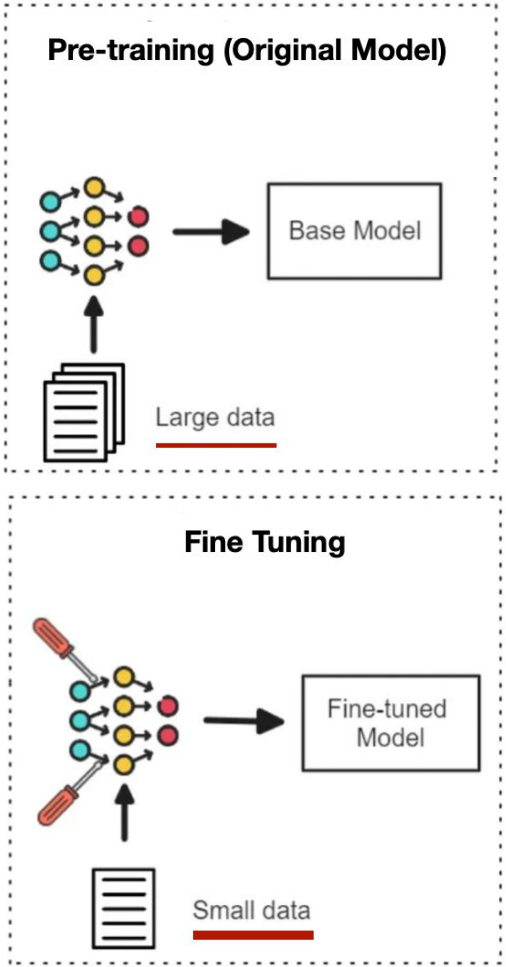
- Prompting (1)
- RAG (2)

Adaptación entrenando (Post-Training)

- SFT (3)
- Instruction Tuning
- RLHF (4)

Fine-tuning

El fine-tuning consiste en **ajustar los pesos de un modelo preentrenado utilizando gradientes calculados sobre datos etiquetados o instruccionales**, minimizando una función de pérdida específica para alinear la distribución de salida del modelo con los requerimientos de una tarea concreta.



Fine-tuning BERT

Link al Colab



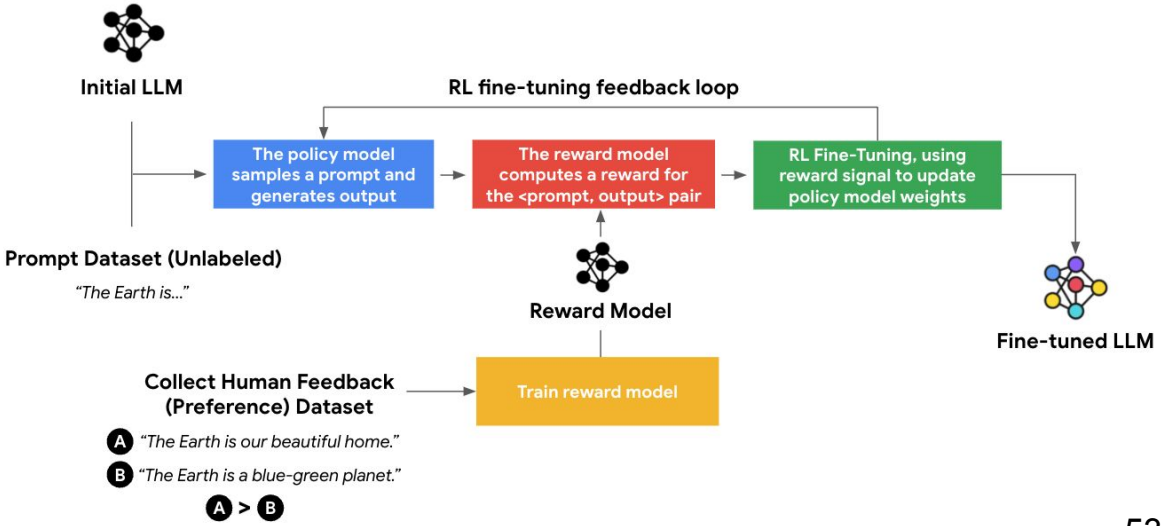
LINK

RLHF

Reinforcement Learning from Human Feedback

RLHF es una técnica que **permite que un modelo de lenguaje aprenda a responder de una manera más útil, segura y alineada con las preferencias humanas.**

El modelo recibe retroalimentación de personas que evalúan varias respuestas y seleccionan cuáles son mejores.



Reinforcement Learning from Human Feedback



ChatGPT: Optimizing Language Models for Dialogue

Note: OpenAI (and similar companies) are keeping more details secret about ChatGPT training (including data, training parameters, model size)—perhaps to keep a competitive edge...

Methods

To create a reward model for reinforcement learning, we needed to collect comparison data, which consisted of two or more model responses ranked by quality. To collect this data, we took conversations that AI trainers had with the chatbot. We randomly selected a model-written message, sampled several alternative completions, and had AI trainers rank them. Using these reward models, we can fine-tune the model using Proximal Policy Optimization. We performed several iterations of this process.

(RLHF!)

ChatGPT utilizó RLHF para ajustar sus pesos.

https://openai.com/blog/chatgpt/

44

Reinforcement Learning from Human Feedback

Problemas éticos del RLHF

BUSINESS + TECHNOLOGY

Exclusive: OpenAI Used Kenyan Workers on Less Than $2 Per Hour to Make ChatGPT Less Toxic

15 MINUTE READ



MIAMI HERALD BUSINESS 15.10.2023 08:00 AM

Millions of Workers Are Training AI Models for Pennies

From the Philippines to Colombia, low-paid workers label training data for AI models used by the likes of Amazon, Facebook, Google, and Microsoft.



Oskarina Vera Fuentes with her dog. COURTESY OF OSKARINA VERA FUENTES

Behind the AI boom, an army of overseas workers in 'digital sweatshops'

By Rebecca Tan and Regine Cabato

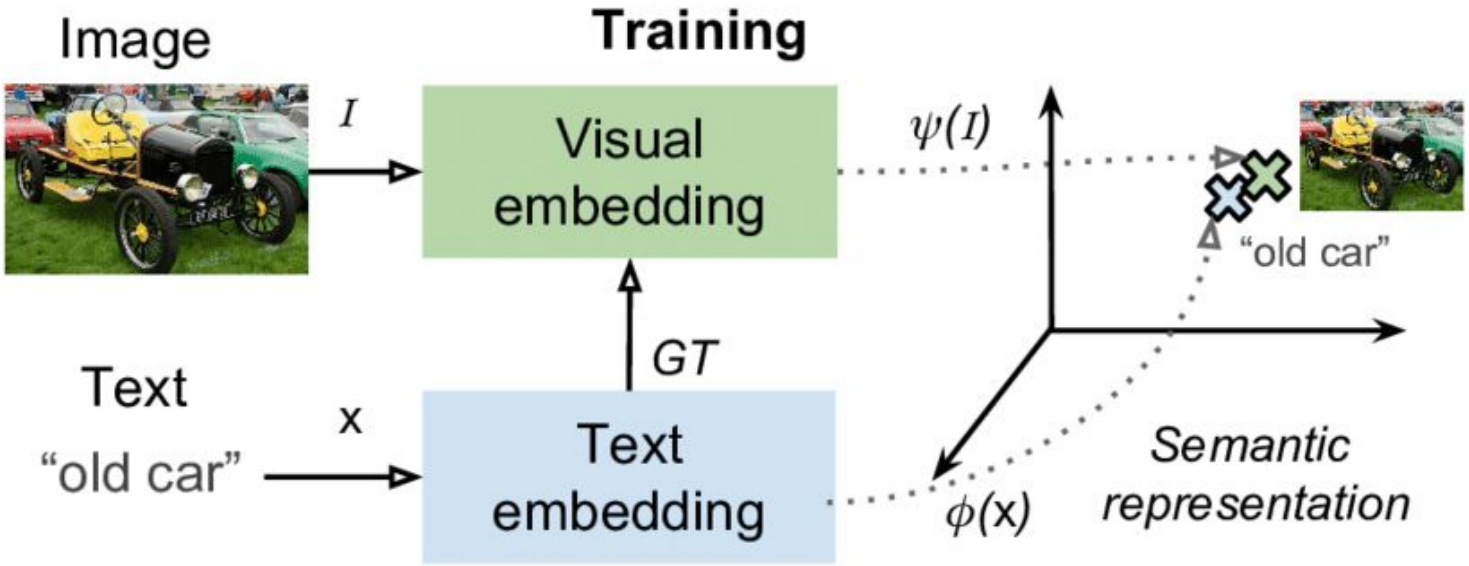
August 29, 2023 at 2:00 a.m. EDT



Actualidad y futuro de NLP

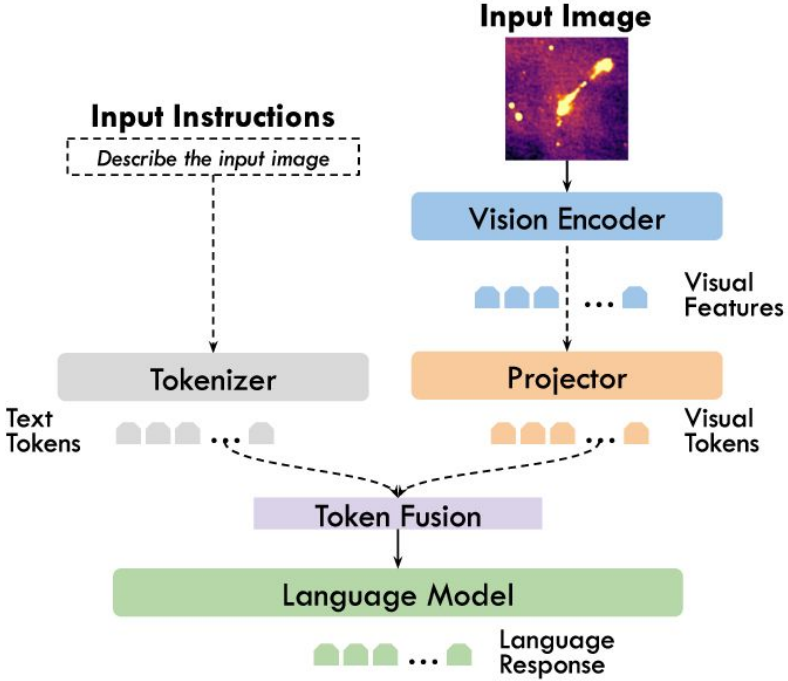
Introducción a Multimodalidad

La multimodalidad es la capacidad de un sistema de inteligencia artificial para comprender y combinar diferentes tipos de información, como texto, imágenes, audio o video, al mismo tiempo.

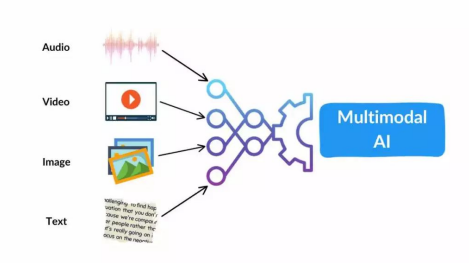


Introducción a Multimodalidad

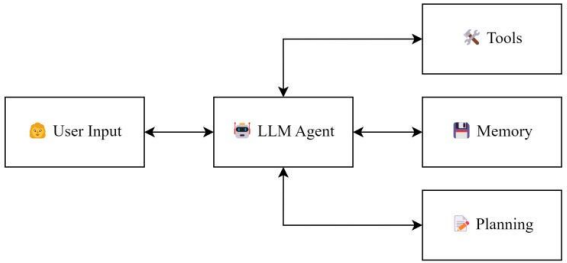
LLaVA (Large Language and Vision Assistant) es un modelo multimodal que combina un encoder visual con un LLM para que pueda entender imágenes y responder preguntas sobre ellas.



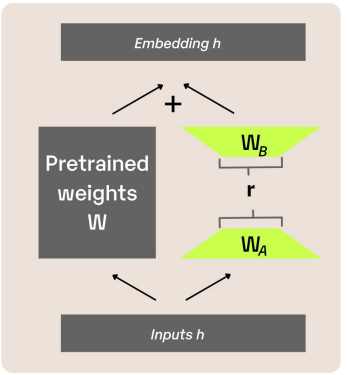
Actualidad y futuro de NLP



Multimodalidad



LLMs + Agentic Systems



NLP Eficiente

¡Muchas gracias!